Regresyon ve Sınıflandırma

- Temel fark
  - Sınıflandırmada sıralı olmayan kategorik bir hedef değişken vardır.
  - Regresyon probleminde sürekli ya da sıralı bir hedef değişken vardır.
- Tüm regresyon yaklaşımları, sınıflandırma problemini çözmek için kullanılabilir.
- Sınıflandırma problemi doğru karar verme sınırını bulmaktan ibarettir (benim bakış açım)

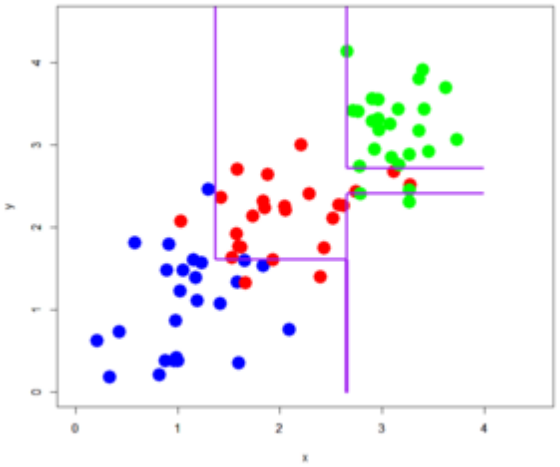

veya

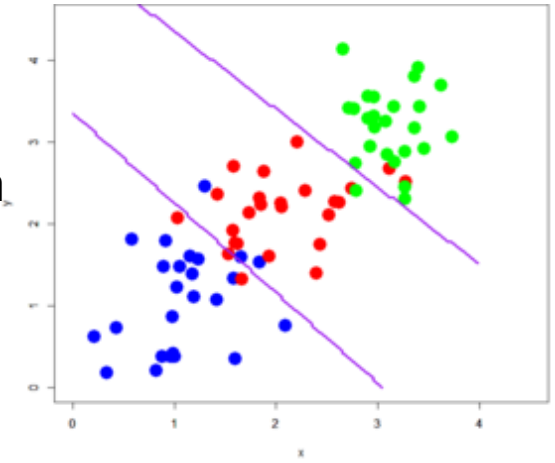

Ayrımcı yaklaşıma karşı **Üretici yaklaşım**

Discriminative versus Generative

Sınıflandırma için doğrusal regresyon kullanımı

- Doğrusal regresyon

$$\hat{Y} = \hat{\beta}_0 + \sum_{j=1}^{p} X_j \hat{\beta}_j.$$

kesen ← → katsayılar

Öznitelik vektörünü kullanarak

$$X^T = (X_1, X_2, \ldots, X_p)$$

$$\hat{Y} = X^T \hat{\beta}, \longrightarrow$$ *Küçük kareler yöntemi (least-squares) ile elde edilir

Sürekli bir tahmin elde edebiliriz.

*Least-squares toplam hatayı enazlamayı hedefler

Sınıflandırma için doğrusal regresyon kullanımı

- Hataların karelerinin toplamını enazlama

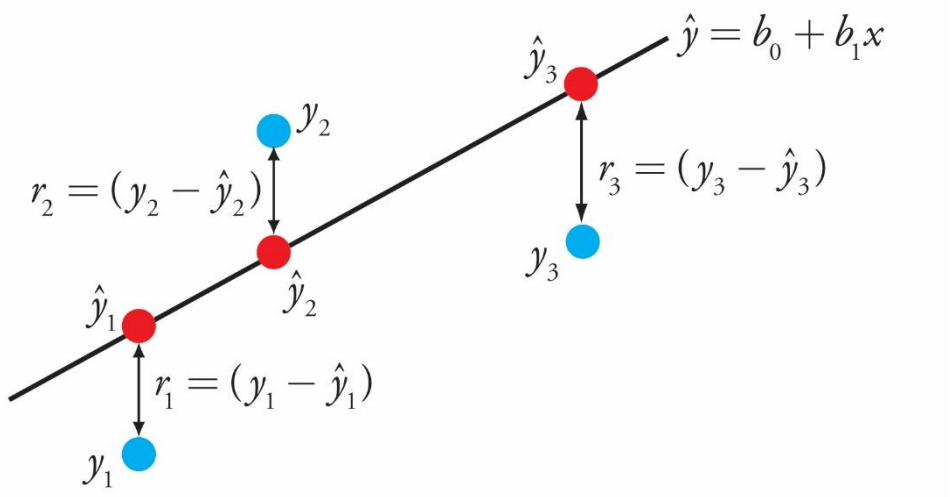

- İki sınıflı bir problemimiz olsun

X1	X2	Class
7.40	1.91	BLUE
3.92	0.24	ORANGE
2.15	1.08	ORANGE
-2.36	0.70	BLUE
.	.	.
.	.	.
.	.	.
0.09	-1.75	ORANGE
0.71	0.67	BLUE

Sınıflandırma için doğrusal regresyon kullanımı

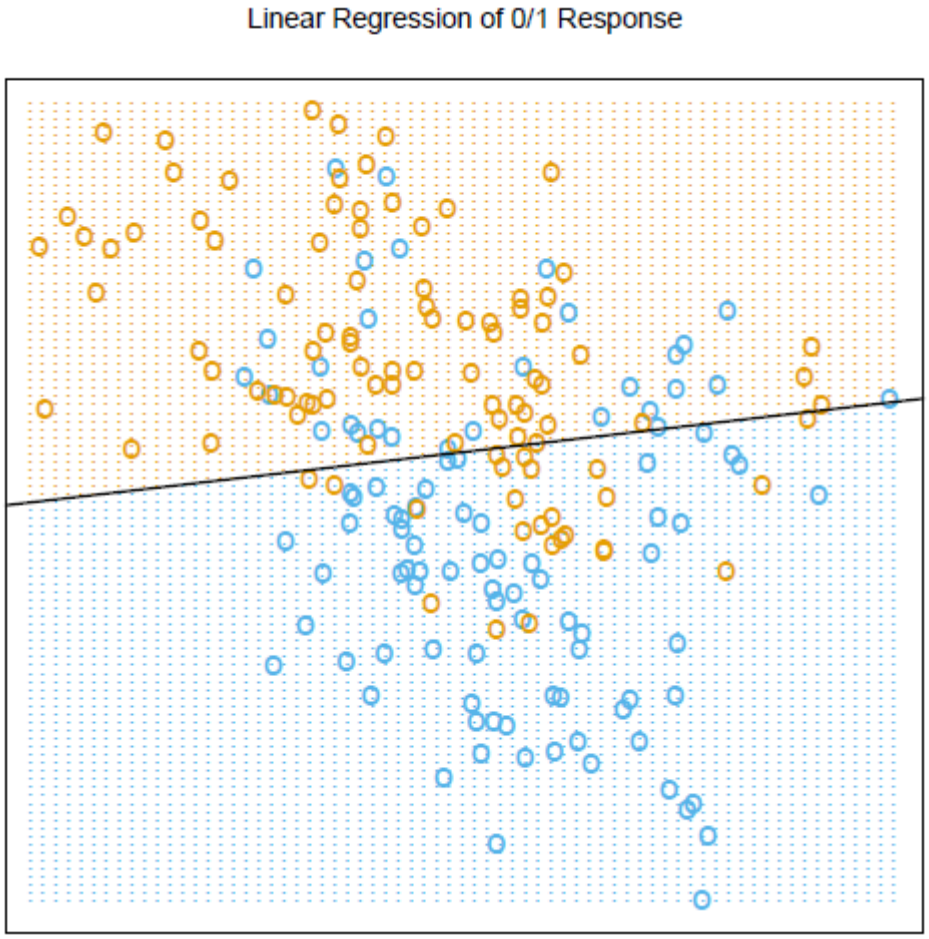

X1	X2	Class
7.40	1.91	0
3.92	0.24	1
2.15	1.08	1
-2.36	0.70	0
.	.	.
.	.	.
.	.	.
0.09	-1.75	1
0.71	0.67	0

Sınıflandırma için doğrusal regresyon kullanımı

- Problemler
  - Doğrusal regresyon varsayımları
    - Normal dağılan hatalar
  - Sadece iki sınıflı problemler için çalışır
    - İkiden fazla farklı sınıf için?
  - Kategorik ya da ordinal değişkenler
    - Sayısal gösterimi gerektirir
  - Doğrusal olma zorunluluğu
    - Polinom terimler eklemek (örn. X^2)
    - Etkileşim terimleri eklemek (örn. XY)
  - Pratikte bir kesme noktası (threshold) belirlemeyi gerektirir.

Sınıflandırma
Lojistik regresyon

- Neden? (Doğrusal regresyon tercih edilmiyor)
  - *Y* sadece iki farklı değer alabildiğinden *e* Normal dağılmamaktadır

$$\hat{Y} = \hat{\beta}_0 + \sum_{j=1}^{p} X_j \hat{\beta}_j \text{ + hata } (e)$$

  - Olasılıklar birden büyük ya da sıfırdan küçük çıkabilir.
- Lojistik regresyon bir dönüşüm ile [0,1] tahminler üretir

$$\Pr(G = 1|X = x) = \frac{\exp(\beta_0 + \beta^T x)}{1 + \exp(\beta_0 + \beta^T x)},$$

$$\Pr(G = 2|X = x) = \frac{1}{1 + \exp(\beta_0 + \beta^T x)}.$$

Sınıflandırma
Lojistik regresyon

- Lojistik ve Doğrusal Regresyon

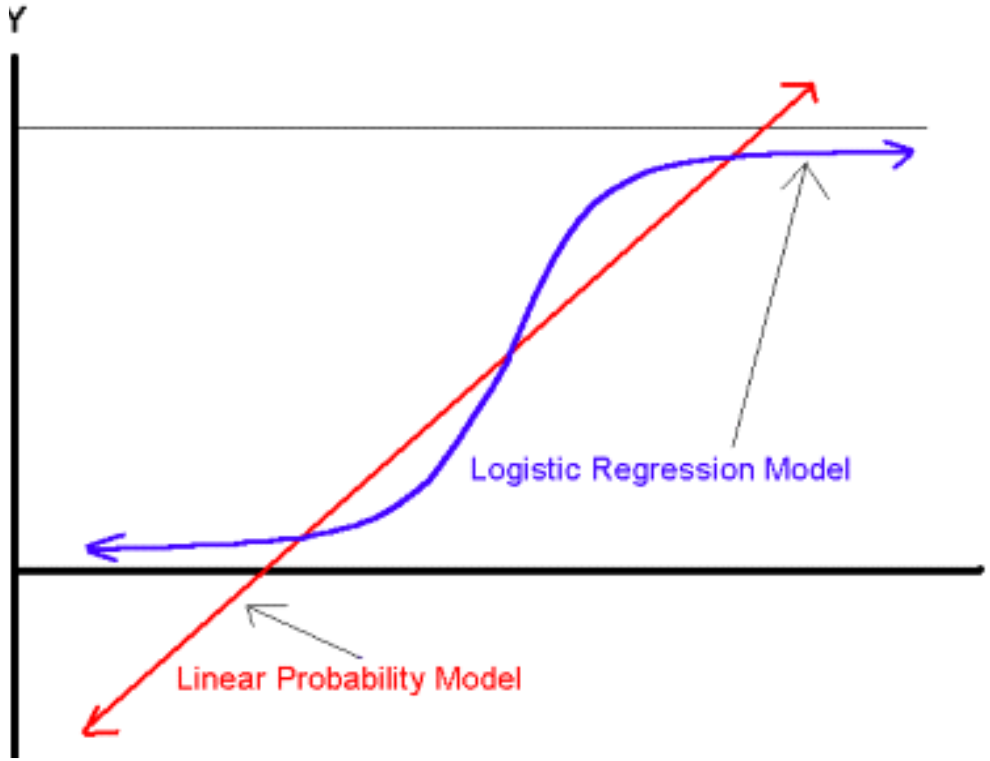

Doğrusal regresyon

$$\hat{Y} = \hat{\beta}_0 + \sum_{j=1}^{p} X_j \hat{\beta}_j.$$

Lojistik regresyon

$$\Pr(G = 1|X = x) = \frac{\exp(\beta_0 + \beta^T x)}{1 + \exp(\beta_0 + \beta^T x)}$$

$$\Pr(G = 2|X = x) = \frac{1}{1 + \exp(\beta_0 + \beta^T x)}$$

Sınıflandırma
Doğrusal olmayan durumlar

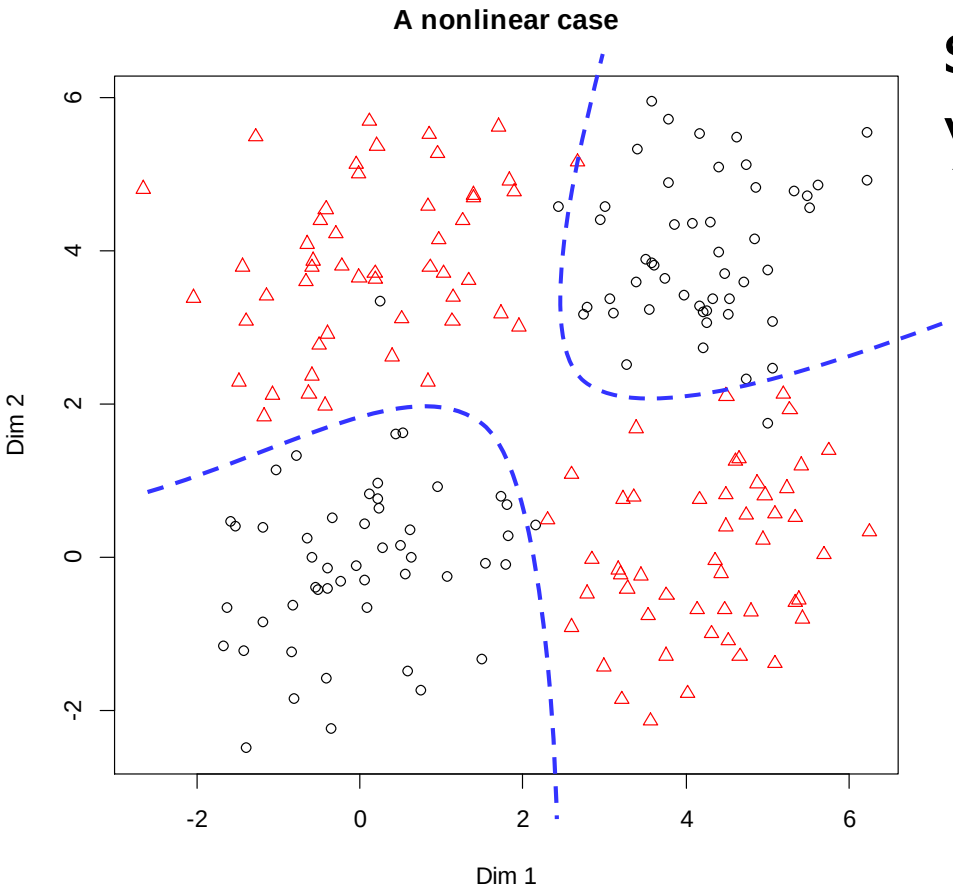

Doğrusal karar verme sınırları çalışmazsa ne yapmalı?

- Doğrusal olmayan terimlerin eklenmesi
  - Neler olabilir?
- Doğrusal olmayan ilişkileri modelleyebilen yöntemlerin kullanımı
  - Birden fazla model vardır.
  - En kolayı ve bilineni En Yakın Komşu (Nearest Neighbor-NN) yöntemidir.

Sınıflandırma
En Yakın Komşu

- Temel fikir
  - Eğer test hayvanı ördek gibi yürüyorsa, ördek gibi ses çıkarıyorsa, büyük ihtimal ile ördektir.

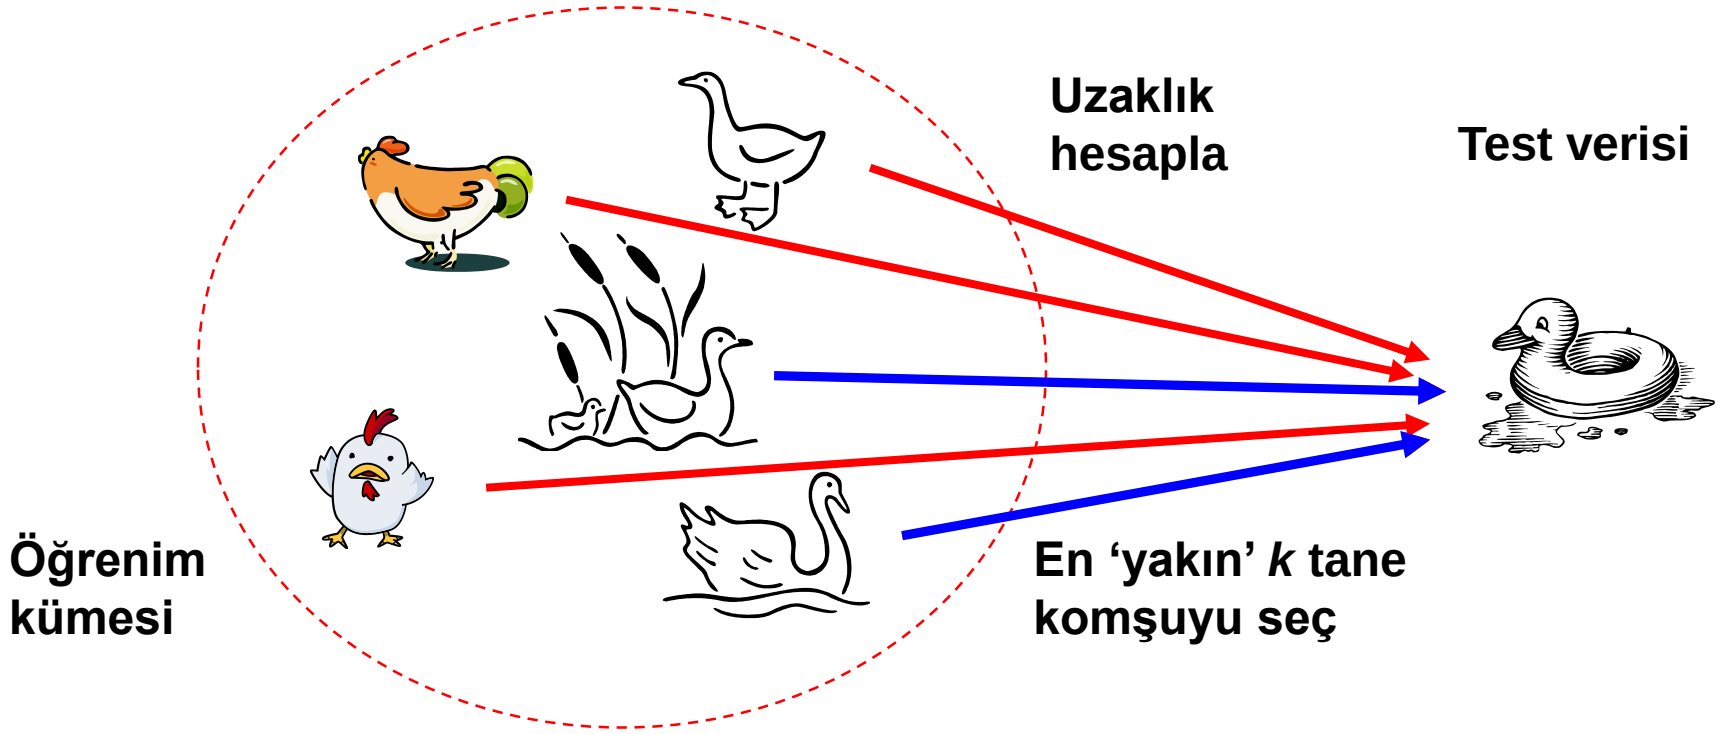

Sınıflandırma
En Yakın Komşu

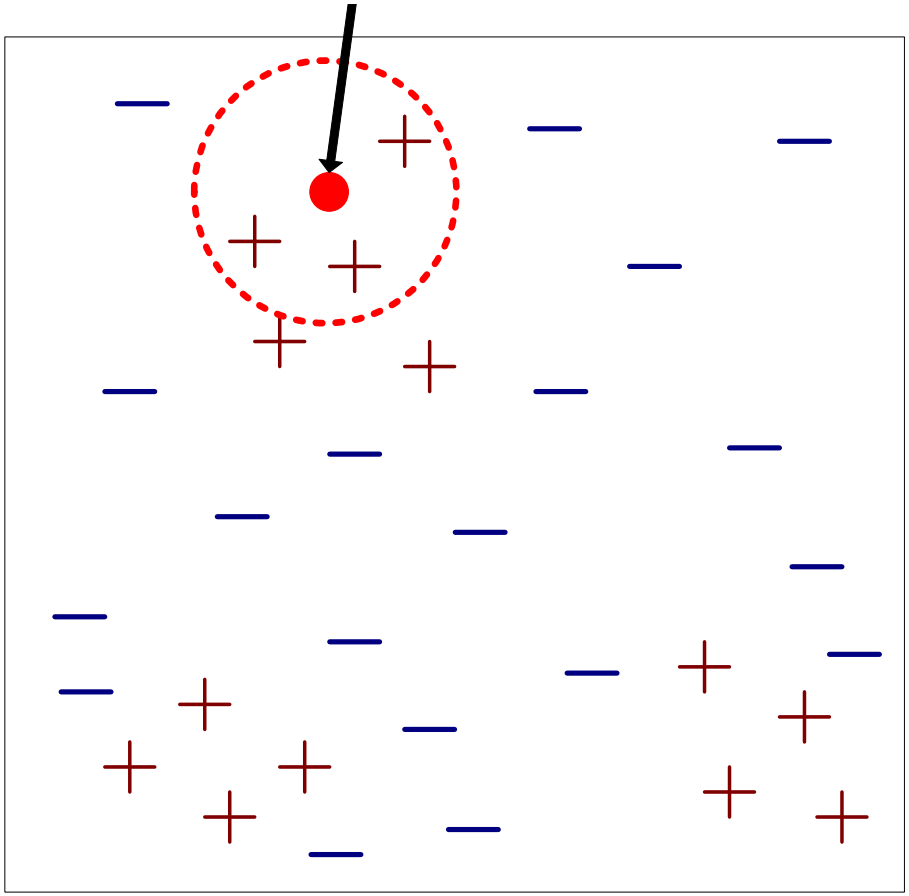

- Üç şey gerektir
  - Kaydedilmiş öğrenme verisi
  - Uzaklık ölçüsü
  - *k* değeri, seçilecek en yakın komşu sayısı
- Sınıflandırma yapmak için
  - Öğrenim verisine uzaklıkları hesapla
  - En yakın *k* komşuyu bul
  - En yakın komşuların sınıfını kullanarak oylama sonucu sınıfa karar ver

Sınıflandırma
En Yakın Komşu

- ***k***-en yakın komşu tahmini

$$\hat{Y}(x) = \frac{1}{k} \sum_{x_i \in N_k(x)} y_i,$$

$N_k(x)$ örnek x için k en yakın öğrenim verisi seti

- En yakın noktaların y değerlerinin ortalaması
  - Regresyon problemi çözümü?
- Sınıflandırma için?
  - Mod alınabilir
- Ağırlık ortalama?
  - Nasıl?

Sınıflandırma
En Yakın Komşu

- *k* nasıl seçilmeli?
  - Çok küçük *k*, gürültüden etkilenme
  - Çok büyük *k*, komşuluk diğer sınıfları içerebilir.

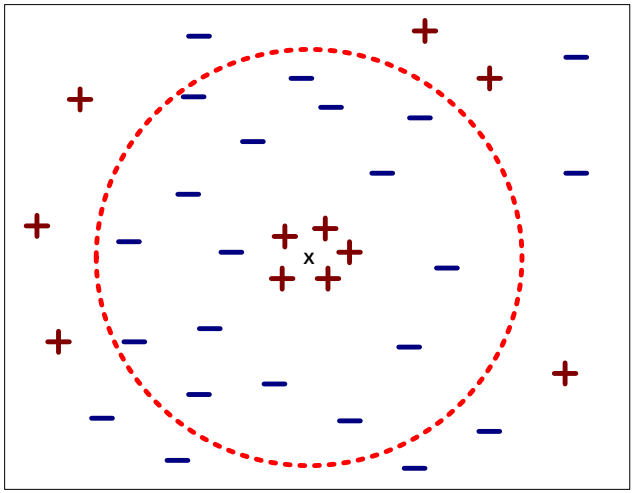

Sınıflandırma
En Yakın Komşu

- Farkı *k* değerleri için karar verme sınırları

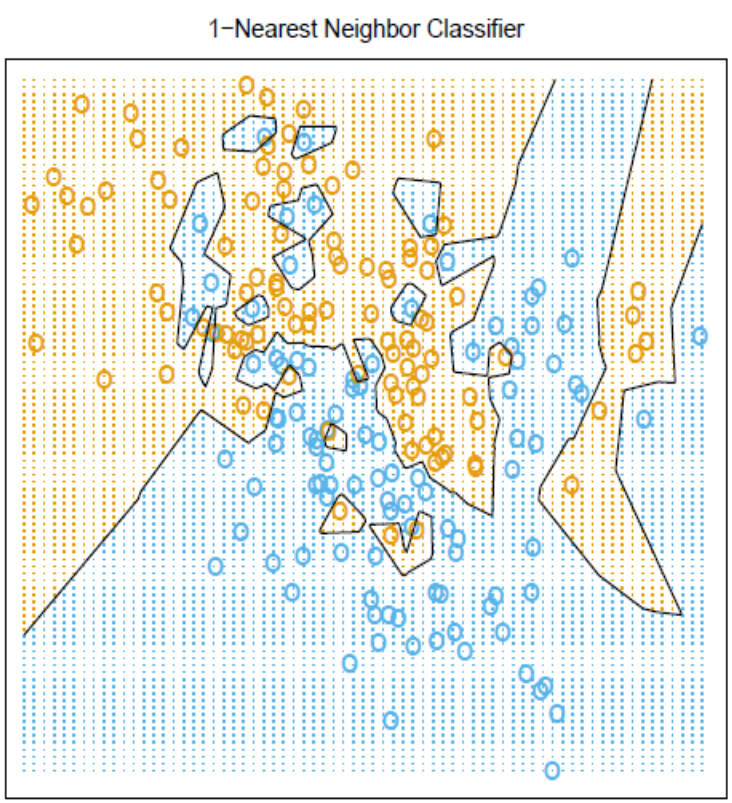

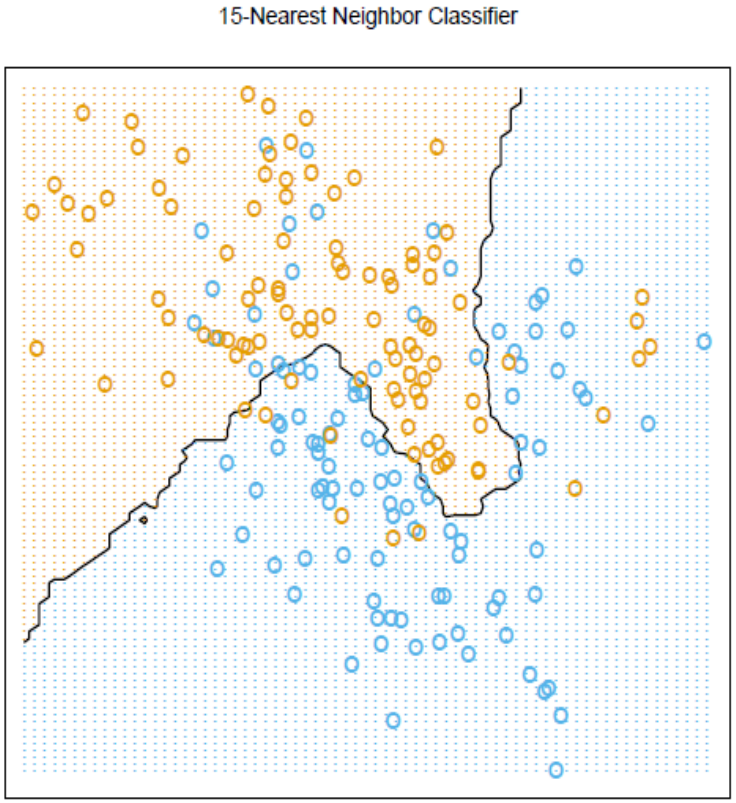

Sınıflandırma
En Yakın Komşu

- Tembel öğrenici (Lazy learner)
  - Altında bir model yok
    - Yoruma açık değil
  - Test verisindeki noktanın öğrenme verisindeki her noktaya uzaklığı hesaplanmalıdır
    - Gerçek zamanlı uygulamalar için problemli
      - Özellikle öğrenme verisi çok büyükse
    - Hafıza kullanımı açısından etkin değil
      - Öğrenme verisini saklamayı gerektirir
- Bir uzaklık/benzerlik ölçütü gerektirir
  - Öznitelik sayısı arttıkça anlamlı sonuç elde etmek zorlaşır (curse of dimensionality)
- Doğrusal olmayan sınırlar bulabilir

Sınıflandırma
En Yakın Komşu

- Örnek: Zaman serilerinde en yakın komşu bulma
  - EKG veri seti
    - http://www.cs.ucr.edu/~eamonn/time_series_data/
    - İki sınıflı sınıflandırma problemi. EKG verisi ile ritm bozukluğu yaşayan hastaları, sağlıklı hastalardan ayırma problemi
    - Zaman üzerinde 96 gözlem içeren 100 öğrenme verisi
    - 100 test verisi

Performans değerlendirme

- Ölçütler
  - Performansı hangi ölçütler ile değerlendirebiliriz?
- Performans ölçme yöntemleri nedir?
  - Modelin başarılı tahminler üretip üretmeyeceği konusunda nasıl fikir elde edebiliriz?
- Farklı modelleri nasıl karşılaştırabiliriz?
  - Farklı modeller arası en iyi modeli nasıl seçeriz?

Performans değerlendirme

- Sınıflandırma algoritması belirlemek birden çok aşamayı içerir
  - Öğrenme verisi kullanarak model oluşturulur
  - Test örnekleri üzerinde değerlendirme yapılır
  - Yeni örnekler üzerinde tahminler elde edilir.

Öğren ve test et paradigması!

Değerlendirme kriteri

- *Tahmin doğruluğu*: Modelin yeni/model oluşturmada kullanılmamış veri üstünde doğru tahminler üretme başarısı
  - doğruluk=test verisinde doğru tahmin edilen gözlem yüzdesi
- *Yorumlanabilirlik*: Modelin anlaşılırlığı ve tahmin problemi hakkında fikir vermesi
- *Gürbüzlük(Robustness)*: Modelin farklı koşullar altında doğru tahmin yapabilmesi
  - Parametre değerleri değiştiğinde
  - Gürültülü ya da kayıp veriler olduğunda

Değerlendirme kriteri

- *Hız*: modeli kurarken ve kullanırken geçen zaman
- *Ölçeklenebilirlik*: veri seti büyüse dahi etkin biçimde model kurabilme
- *Basitlik:* Modelin çalışma prensiplerinin kolay anlaşılması

Model değerlendirme
Performans ölçümü için metrikler

- Modelin tahmin kabiliyetine odaklanır
  - Hızlı ya da ölçeklenebilir olmayı hesaba katmaz
- Öğrenme kümesine ait olmayan veriler üzerinde değerlendirmek anlamlıdır
  - N_t – test verisi sayısı
  - N_c – doğru tahmin edilen test örneği
  - Tahmin doğruluğu: $$\eta = \frac{N_c}{N_t}$$
  - Tahmin hatası: $$\varepsilon = \frac{N_t - N_c}{N_t}$$

Model değerlendirme
Performans ölçümü için metrikler

- Kararsızlık matrisi:
  - İkili (2-sınıf) sınıflandırma

		PREDICTED CLASS	
		Class=Yes	Class=No
ACTUAL CLASS	Class=Yes	a	b
	Class=No	c	d

a: TP (gerçek pozitif)

b: FN (yanlış negatif)

c: FP (yanlış pozitif)

d: TN (gerçek negatif)

- Kararsızlık matrisine bağlı olarak birden çok değerlendirme metriği kullanılmaktadır

	Predicted		
Original classes	K_1	K_2	K_3
K_1	50	0	0
K_2	0	48	2
K_3	0	4	46

3 sınıf içeren problem örneği

Model değerlendirme
Performans ölçümü için metrikler

- Doğruluk kullanımı uygulamaya bağlı olarak problemli olabilir
  - İki sınıflı problem
    - Sıfır sınıfından örnek sayısı= 9990
    - Bir sınıfından örnek sayısı = 10
  - Eğer model herşeyi sıfır olarak tahmin ederse tahmin başarısı= 99.9 %
- Maliyet matrisi

C(i | j): j sınıfından bir örneği i sınıfı olarak tahmin etmek

		PREDICTED CLASS	
	C(i|j)	**Class=Yes**	**Class=No**
ACTUAL CLASS	**Class=Yes**	C(Yes|Yes)	C(No|Yes)
	Class=No	C(Yes|No)	C(No|No)

Model değerlendirme
Performans ölçümü için metrikler

- Farklı hata tiplerine değişen maliyetler
- Tüm hataların maliyeti aynı değildir
  - Kredi geri ödemeleri
    - Kredisini geri ödemeyen insan müşteri kaybından daha maliyetlidir
  - Tıbbi testler
    - Yanlış teşhisin hastalığı teşhis edememe durumuna göre maliyeti farklıdır
  - Spam
    - Spam e-postayı kaçırmak ile önemli bir maili spam diye gözden kaçırma maliyeti farklıdır
- Algoritmaları yanlış pozitif ve yanlış negatifin bize yaratacağı maliyetleri hesaba katarak öğrenmek gerekir.

Model değerlendirme
Performans ölçümü için metrikler

- Sınıflandırma maliyetini hesaplama

Cost Matrix	PREDICTED CLASS		
	C(i|j)	+	-
ACTUAL CLASS	+	-1	100
	-	1	0

Model M_1	PREDICTED CLASS		
		+	-
ACTUAL CLASS	+	150	40
	-	60	250

Doğruluk = 80%

Maliyet = 3910

Model M_2	PREDICTED CLASS		
		+	-
ACTUAL CLASS	+	250	45
	-	5	200

Doğruluk = 90%

Maliyet = 4255

Model değerlendirme yöntemleri

- Performansı ölçebilen güvenilir bir ölçüt nasıl bulunur?

- Model performansı **öğrenme algoritmasının** yanı sıra birden çok etkene bağımlı olabilir:
  - Sınıf dağılımı
  - Yanlış sınıflandırmanın maliyeti
  - Öğrenme ve test etme veri büyüklüğü

Tek önemli karar değildir

Problem nitelikleri önemlidir

Model değerlendirme yöntemleri
Kestirim stratejileri

- Örneklem içi (In-sample) değerlendirme
  - Eldeki tüm veriyi model parametrelerini öğrenmek için kullanır
  - Amaç modelin eldeki veriyi ne kadar iyi açıkladığını anlamaktır
  - Parametre sayısını azaltmak amaçlanır
- Örneklem dışı (out-of-sample) değerlendirme
  - Split data into training and test sets
  - Focus: how well does my model predict things
  - Prediction error is all that matters
- İstatistik genelde örneklem içi değerlendirmeye odaklanır, makine öğrenmesi/veri madenciliği yöntemleri ise örneklem dışı değerlendirmeyi ön planda tutar.

Model değerlendirme yöntemleri
Kestirim stratejileri

- Dışarda bırakma (holdout)
  - Öğrenme için verinin 2/3 ve test için 1/3 ünü kullanma
- Cross validation (çapraz eşleme - bağımsız geçerlilik sınaması)
  - Veriyi *k* tane ayrık kümelere böl
  - *k*-fold: her seferin de bir kümeyi test verisi dışarda bırak, geri kalan k-1 kümeyi öğrenme verisi olarak kullan
  - Birini dışarda bırak (Leave-one-out): $k=n$
- Rastgele alt örneklem alma (Random subsampling)
  - Tekrarlayan dışarda bırakma
- Katmanlı örneklem alma (Stratified sampling)
  - Fazla örneklem alma (oversampling) ve az örneklem alma (undersampling)

Model değerlendirme yöntemleri
Kestirim stratejileri

- Dışarda bırakma yöntemi genellikle verinin 1/3 ünü test verisi 2/3 ünü ise öğrenme verisi olarak kullanır
- Sınıf dağılımı açısından dengesiz veri setleri (class imbalance) rastgele alınan örneklemler verideki gerçek dağılımı yansıtmayabilir.
- *Katmanlı örneklem (Stratified sample):*
  - Her alt kümede sınıflar eşit oranlarda ele alınsın

Model değerlendirme yöntemleri
Kestirim stratejileri

- Cross-validation

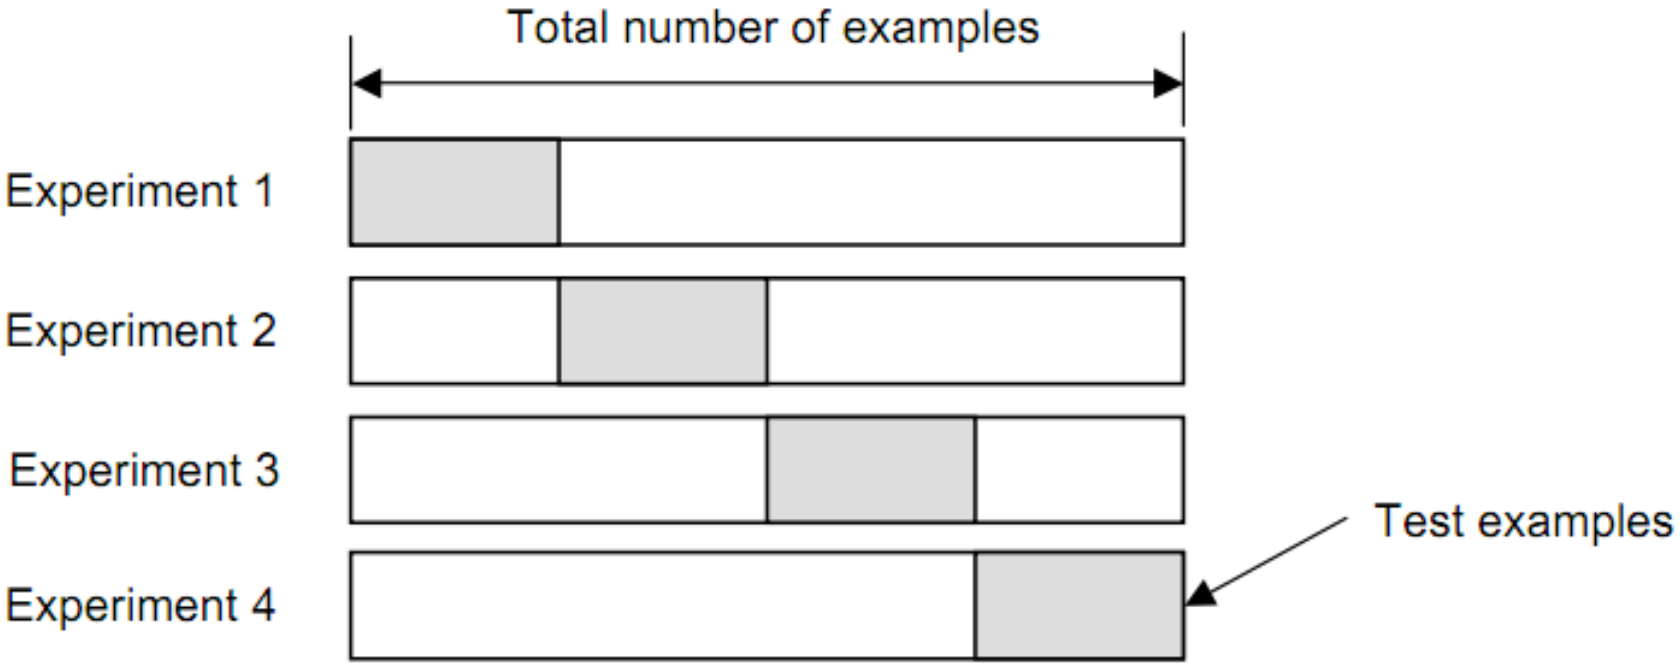

Model değerlendirme yöntemleri
Kestirim stratejileri

- Değerlendirme için kullanılan standart yöntem: katmanlı 10'lu çapraz eşleme (cross-validation)
- Neden 10? Birçok veri setinde yeterli olduğu görülmüştür.
- Tekrarlayan katmanlı çapraz eşleme model performansı hakkına daha iyi fikir verir.
  - Tek bir rastgele seçimle oluşturulmuş çapraz eşleme sonuçlarına güvenmektense, birden çok rastgele seçim yapmak
- Tekrarlar üzerinde elde edilen ortalama performans değerlendirme için en güvenilir ölçüttür.

Model değerlendirme yöntemleri
Kestirim stratejileri

- Bir örneği dışarda bırakan çağraz eşleme (Leave-One-Out (LOO) cross-validation)
  - Veriyi en iyi şekilde kullanır
  - Rassallık içermez
  - Hesaplama zamanı açısından kötüdür ama en güvenilir performans kestirimini sağlar
- Dışarda bırakma yöntemi ile elde edilen öngörü rastgele seçilen örneklemler üzerinde tekrarlanarak daha iyi hale getirilebilir.
  - Her tekrarda katmanlı rastgele seçim yap
  - Farklı tekrarlar üzerinden yapılan hataların ortalamasını al
- Tekrarlayan dışarda bırakma yöntemi

Sınıflandırma
Ağaç-tabanlı yaklaşımlar

	kategorik	kategorik	sürekli	sınıf
Tid	**Refund**	**Marital Status**	**Taxable Income**	**Cheat**
1	Yes	Single	125K	**No**
2	No	Married	100K	**No**
3	No	Single	70K	**No**
4	Yes	Married	120K	**No**
5	No	Divorced	95K	**Yes**
6	No	Married	60K	**No**
7	Yes	Divorced	220K	**No**
8	No	Single	85K	**Yes**
9	No	Married	75K	**No**
10	No	Single	90K	**Yes**

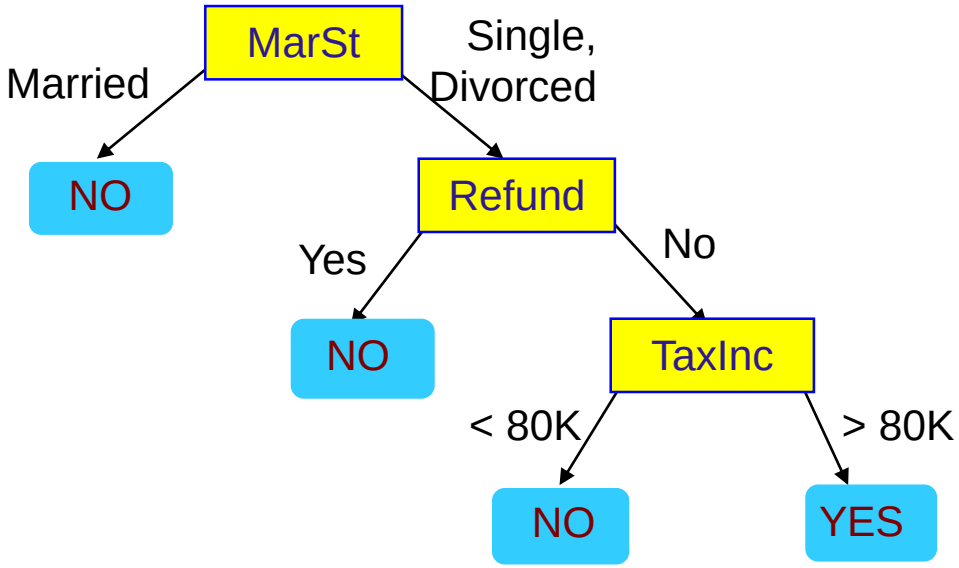

Aynı veriyi açıklayan birden fazla ağaç olabilir

Sınıflandırma
Ağaç-tabanlı yaklaşımlar

kategorik kategorik sürekli sınıf

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

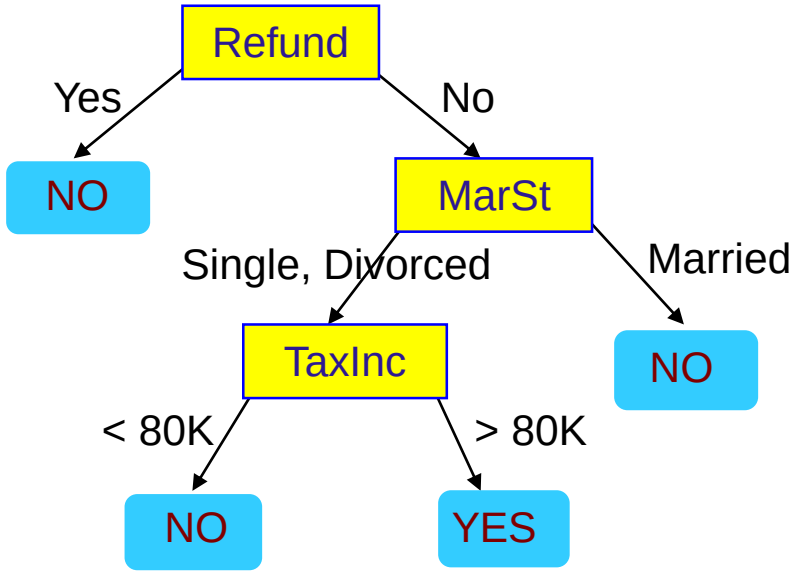

Öğrenme verisi

Model: Karar ağacı

Sınıflandırma
Ağaç-tabanlı yaklaşımlar

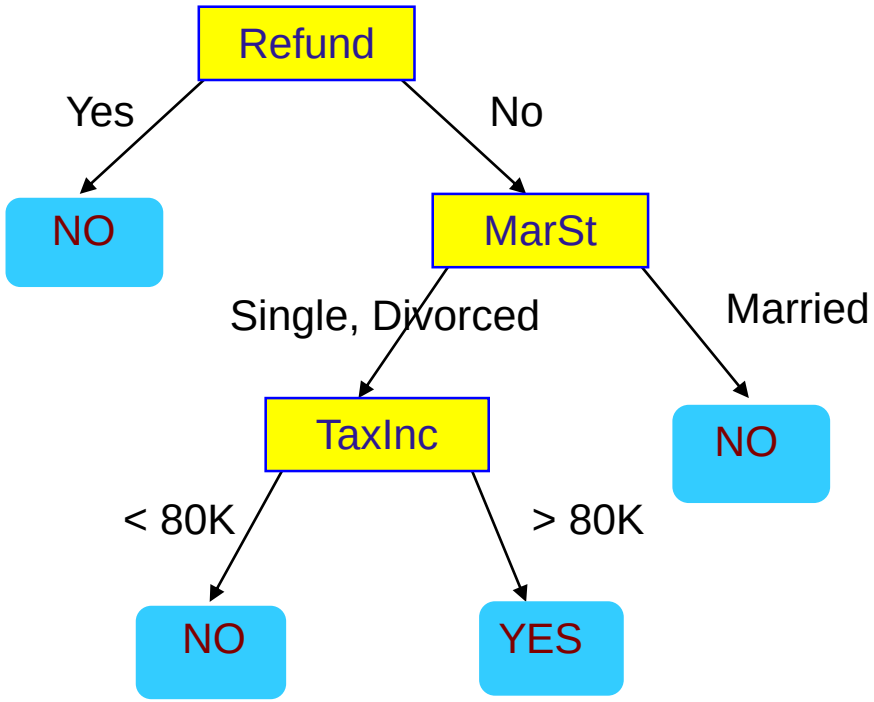

Test Verisi

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?

Sınıflandırma
Ağaç-tabanlı yaklaşımlar

- Öznitelik uzayını bölme
  - Ardışık bölmelerle karar verme sınırı belirleme

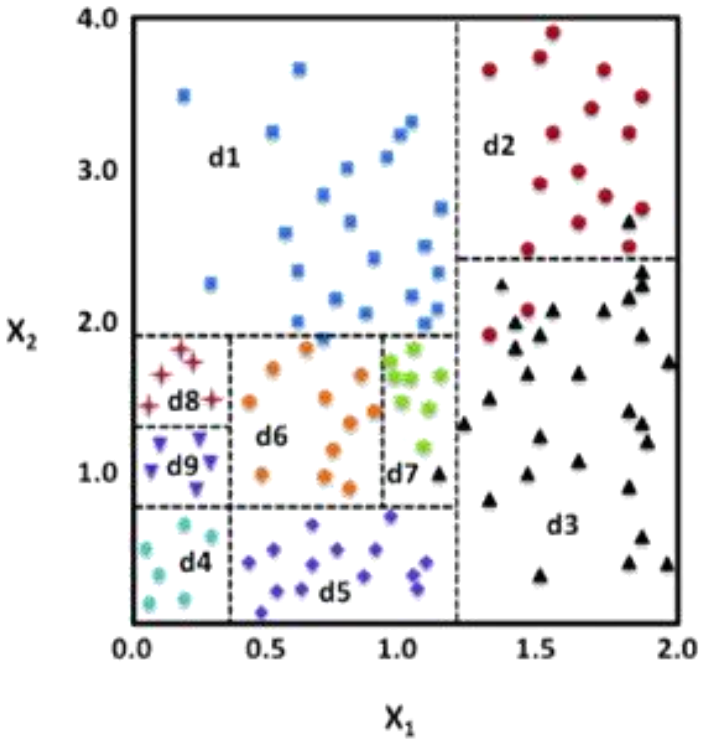

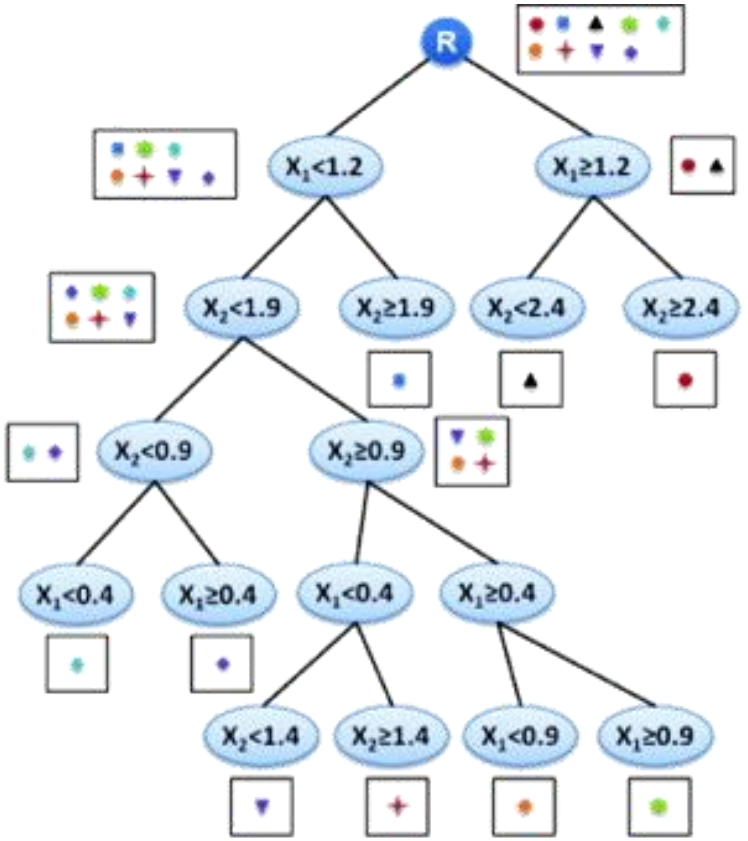

Regresyon
Ağaç-tabanlı yaklaşımlar

İki değişkenimiz olsun (wheelbase and horsepower)

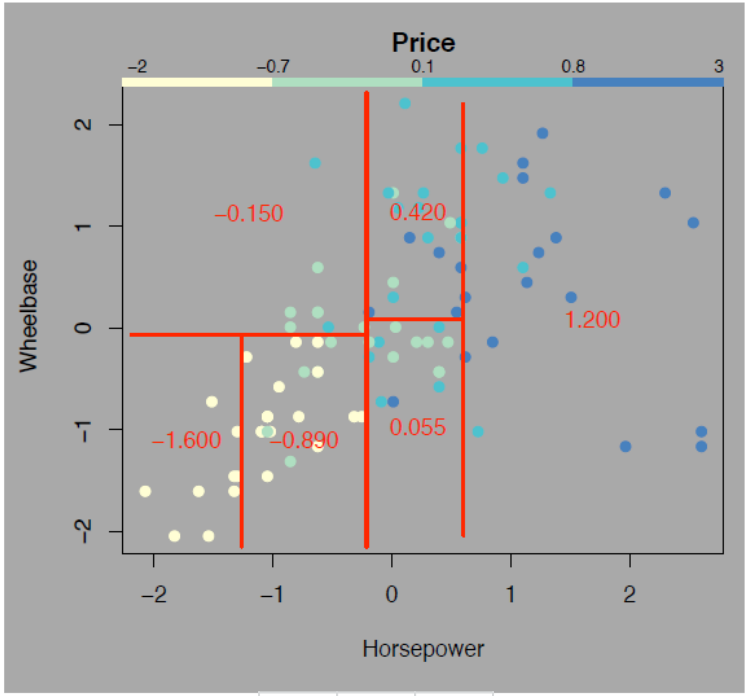

X1	X2	Y
0.499	0.844	0.039
0.325	0.963	0.399
0.905	0.015	0.409
.	.	.
.	.	.
0.879	0.730	0.281

Bu değişkenlerle araba fiyatını tahmin eden bir karar ağacı kuralım

$$m(\mathbf{x}) = \sum_{i=1}^{l} k_i \times I(\mathbf{x} \in D_i)$$

Toplam hatayı en aza indirecek bir D_i bulma

Ağaç-tabanlı yaklaşımlar Öğrenme

- Meseleler
  - Uzayı nasıl bölmeli?
    - Tek seferde kaç parçaya bölmeli?
      - İkili bölümler
      - Çoklu bölümler
    - Bölme kuralı ne olmalı?
      - Hangi öznitelik kullanılacak?
      - Kural ne olacak?
  - Bölme ne zaman durdurulacak

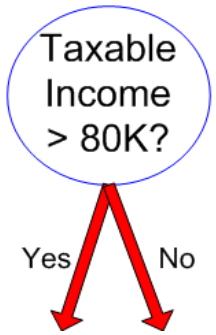

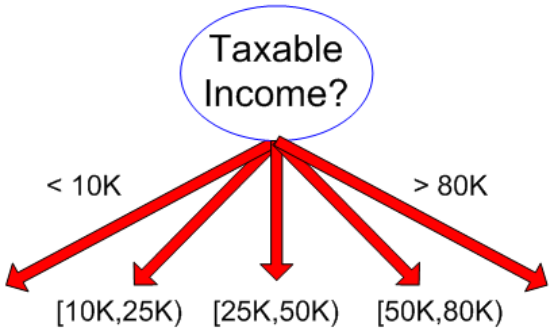

Ağaç-tabanlı yaklaşımlar
Uzayı bölme

- Öznitelik tiplerine göre değişir
  - Kategorik
  - Sıralı
  - Sürekli
- Bölme tiplerine göre değişir
  - İkili
  - Çoklu

Ağaç-tabanlı yaklaşımlar
Uzayı bölme

- Kategorik değerleri bölme
  - Çoklu bölme

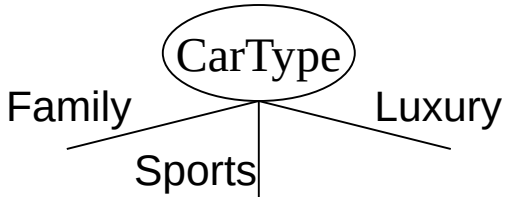

  - İkili bölme

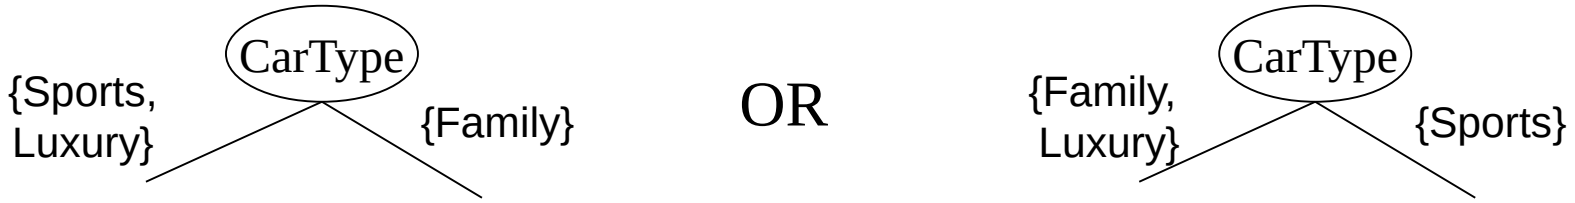

Ağaç-tabanlı yaklaşımlar
Uzayı bölme

- Sıralı değerleri bölme
  - Çoklu bölme

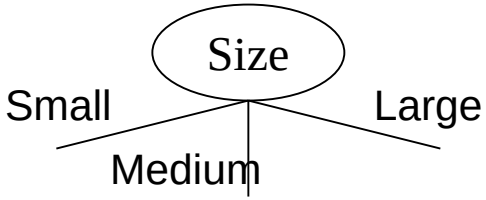

  - İkili bölme

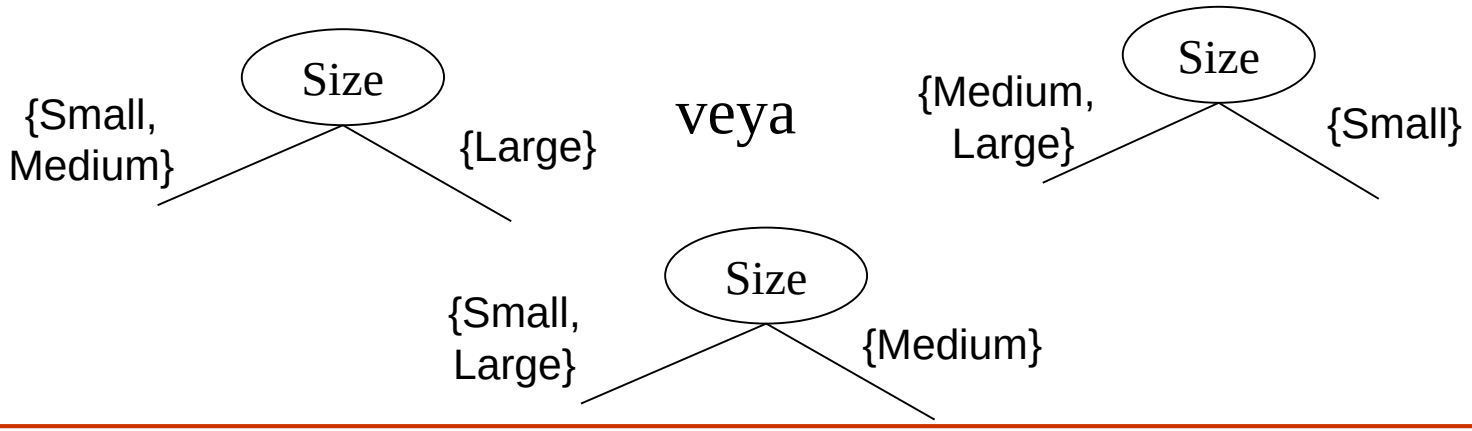

Ağaç-tabanlı yaklaşımlar
Uzayı bölme

- Sürekli değerleri bölme
  - Birden fazla yöntem vardır
    - Kesikli hale getirerek sıralı değişken elde etme
    - İkili kararlar: $(A < v)$ or $(A \geq v)$
      - Olası her sınır arasından en iyisini seç
      - Hesaplama gerektirir.

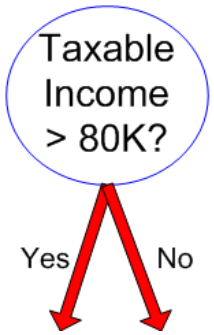

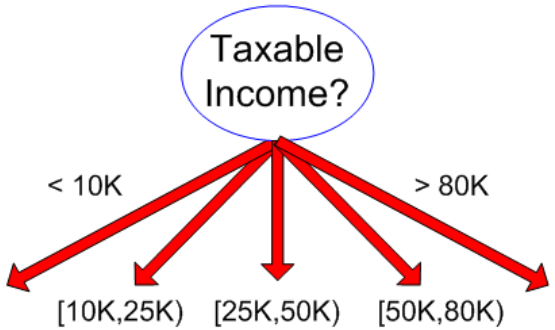

Ağaç-tabanlı yaklaşımlar
Uzayı bölme

- En iyi karar sınırın bulma

Bölmeden önce: Sınıf 0 için 10 örnek,
Sınıf 1 için 10 örnek,

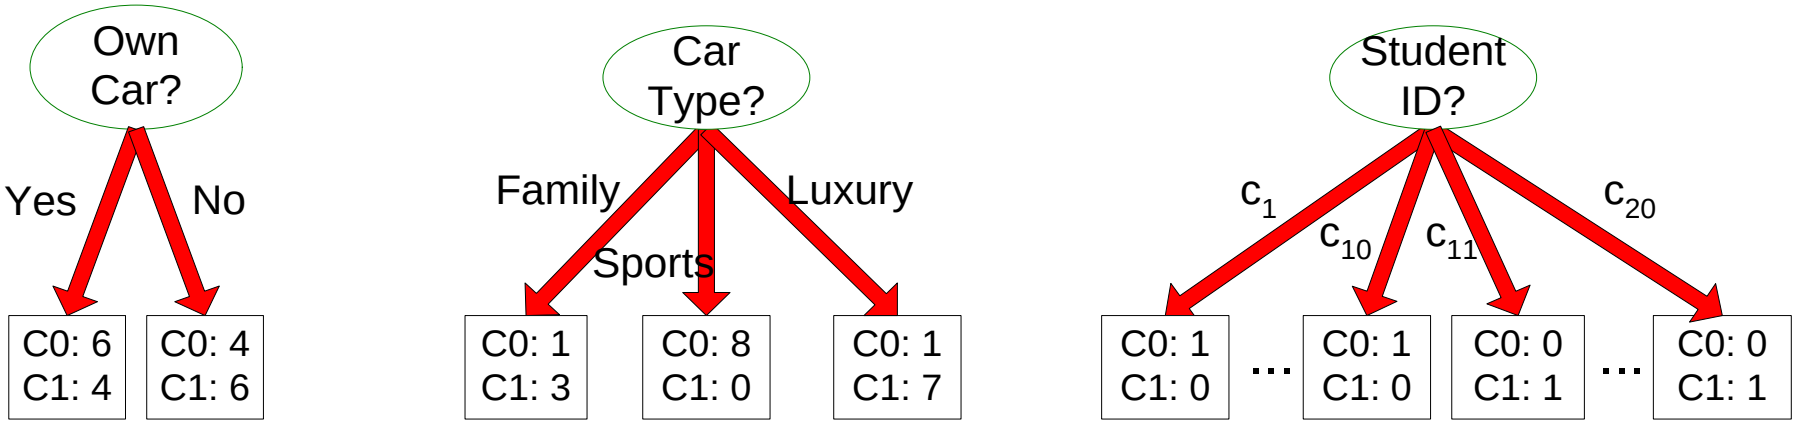

Hangisi en iyisi?

Ağaç-tabanlı yaklaşımlar
Uzayı bölme

- Impurity
  - Bir grup gözlemin sınıf cinsinden homojen olma durumunun ölçütü

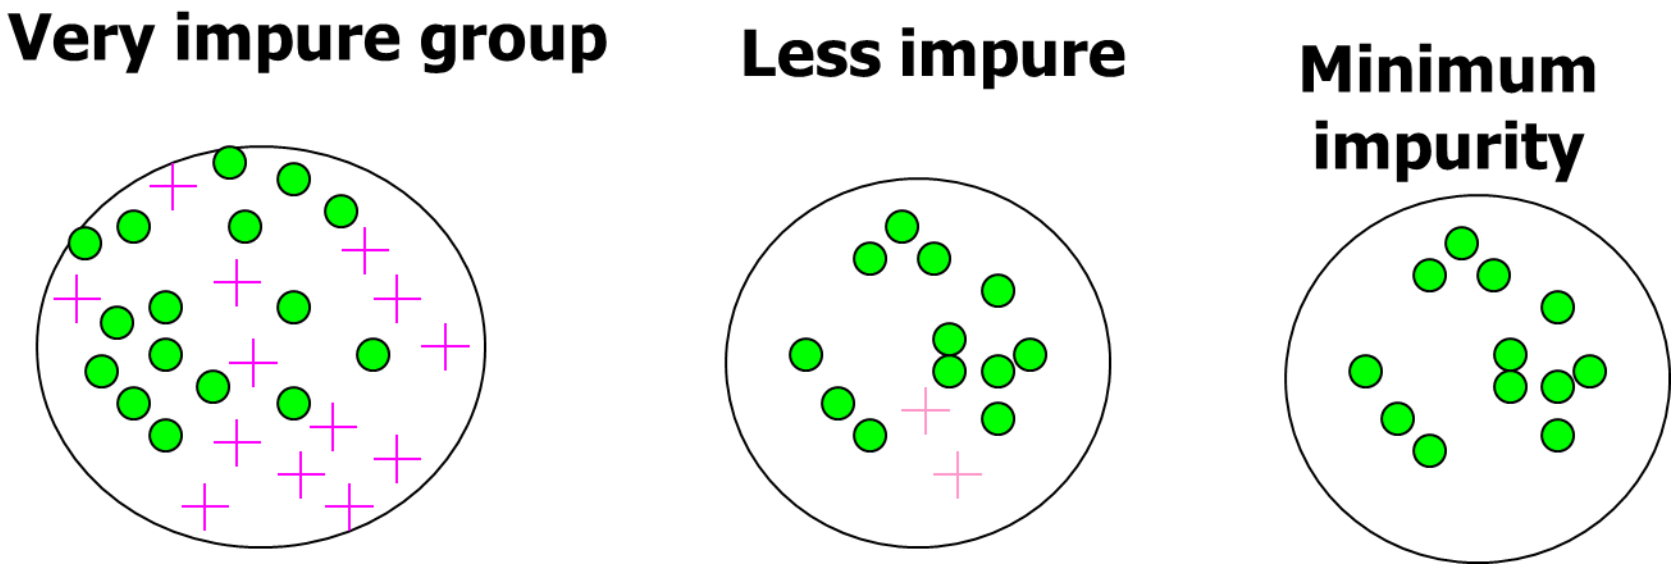

Ağaç-tabanlı yaklaşımlar
Uzayı bölme

- Aç gözlü yaklaşım:
  - Homojen sınıf dağılımı içeren düğümler (node) bulmak
- Saflığın bir ölçütü gerekmekte
  - Gini Index
  - Entropy
  - Tahmin hatası

C0: 5
C1: 5

Homojen değil

C0: 9
C1: 1

Homojen

Ağaç-tabanlı yaklaşımlar
Uzayı bölme

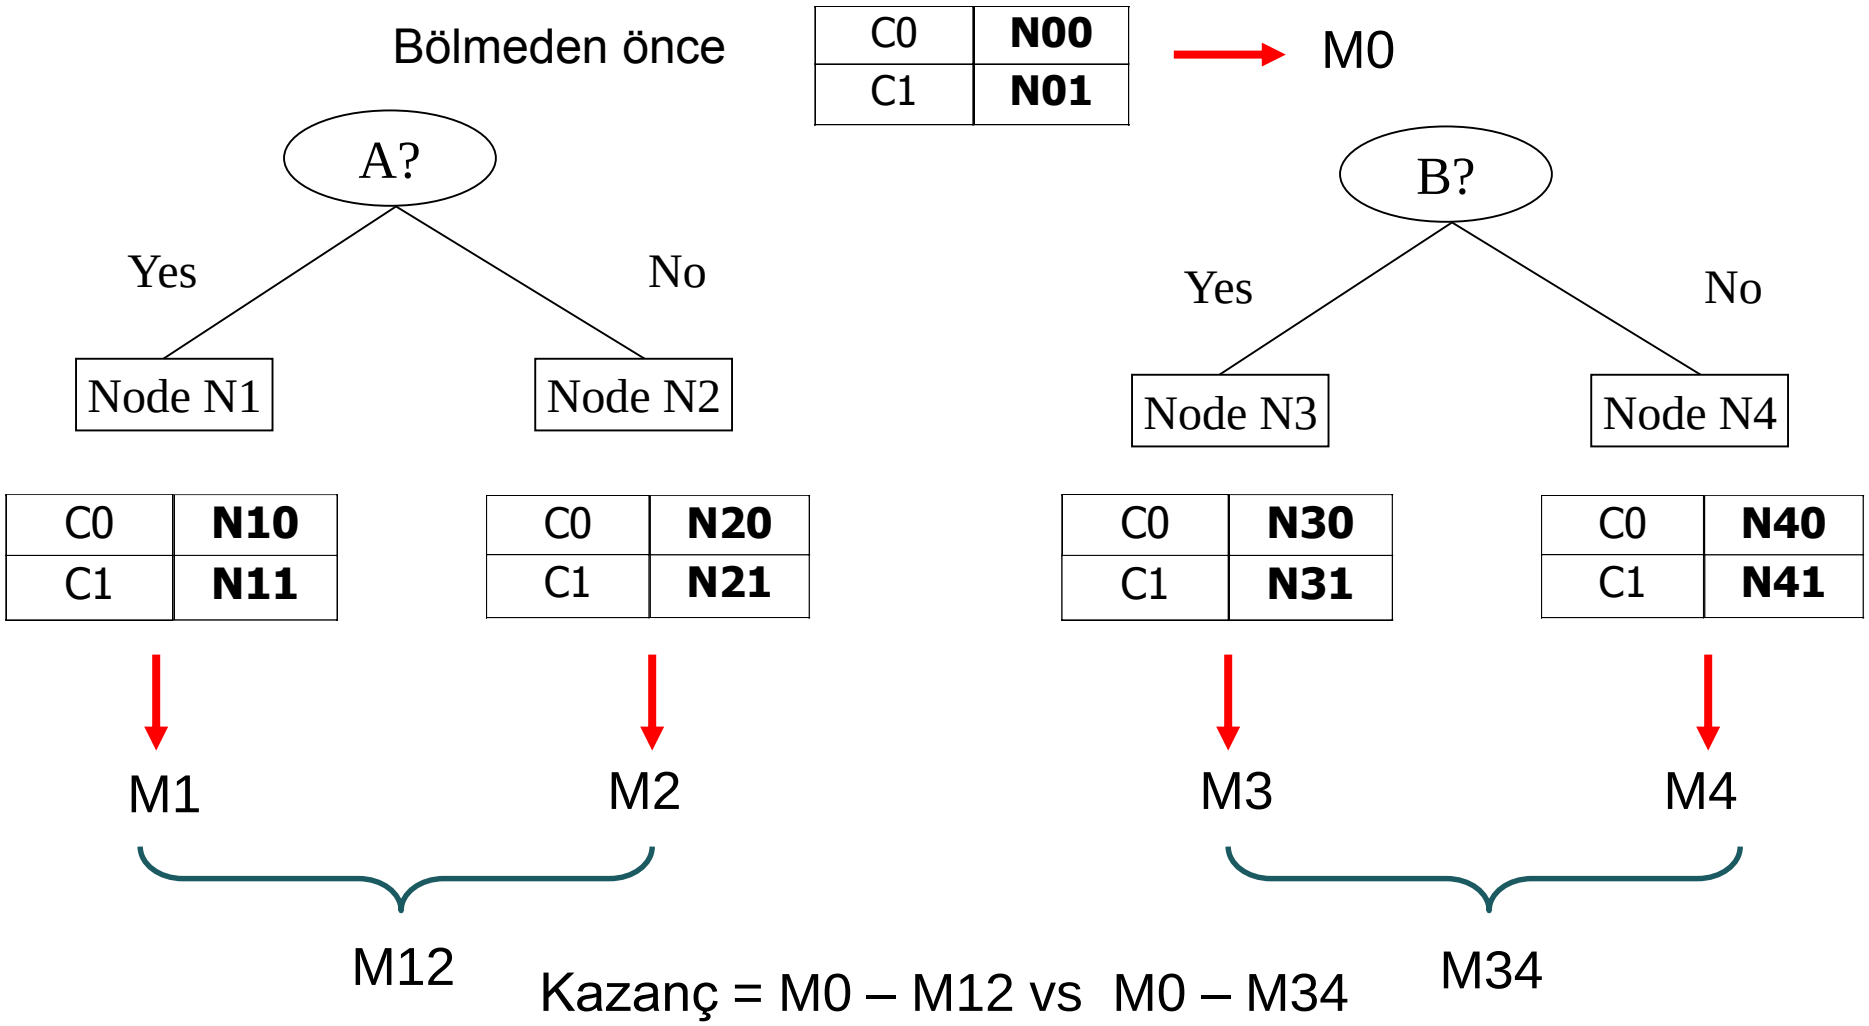

Ağaç-tabanlı yaklaşımlar
Uzayı bölme

- Homojenlik ölçütü

  Düğüm t için Gini Index:

$$GINI(t) = 1 - \sum_j [p(j \mid t)]^2$$

(Not: $p(j \mid t)$ t düğümündeki j sınıfından gözlem oranı)

- Maksimum (1 - 1/n_c) eğer farklı sınıftaki gözlemler eşit olarak dağılmışsa
- Minimum (0.0) eğer tüm gözlemler bir sınıftansa

C1	**0**
C2	**6**
Gini=0.000	

C1	**1**
C2	**5**
Gini=0.278	

C1	**2**
C2	**4**
Gini=0.444	

C1	**3**
C2	**3**
Gini=0.500	

Uzayı bölme
Örnek Gini hesapları

$$GINI(t) = 1 - \sum_j [p(j \mid t)]^2$$

C1	**0**
C2	**6**

P(C1) = 0/6 = 0 P(C2) = 6/6 = 1

Gini = 1 – $P(C1)^2$ – $P(C2)^2$ = 1 – 0 – 1 = 0

C1	**1**
C2	**5**

P(C1) = 1/6 P(C2) = 5/6

Gini = 1 – $(1/6)^2$ – $(5/6)^2$ = 0.278

C1	**2**
C2	**4**

P(C1) = 2/6 P(C2) = 4/6

Gini = 1 – $(2/6)^2$ – $(4/6)^2$ = 0.444

Uzayı bölme
Gini'ye göre bölüm bulma

- Bölümleme kalitesi aşağıdaki gibi bulunur

$$GINI_{split} = \sum_{i=1}^{k} \frac{n_i}{n} GINI(i)$$

n_i = çocuk node i deki gözlem sayısı,

n = başlangıç gözlem sayısı

Uzayı bölme
Gini'ye göre bölüm bulma - Kategorik

Çoklu bölüm

	CarType		
	Family	Sports	Luxury
C1	1	2	1
C2	4	1	1
Gini	0.393		

İkili bölüm

	CarType	
	{Sports, Luxury}	{Family}
C1	3	1
C2	2	4
Gini	0.400	

	CarType	
	{Sports}	{Family, Luxury}
C1	2	2
C2	1	5
Gini	0.419	

Uzayı bölme
Gini'ye göre bölüm bulma - Sürekli

- Bir değere göre ikili kararlar verilir
- Olası birden çok bölme değeri opsiyonu var
  - Olası bölme değerleri = Birbirinden farklı olan tüm değerler
- Her bölme değeri sınıfları sayar
  - Her bölüm için sınıfları say, A < v and A ≥ v
- En iyi v seçme yöntemi
  - Her v için sınıfları say
  - Hesaplama açısından etkin değil.

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

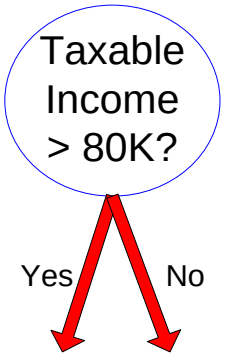

Uzayı bölme
Gini'ye göre bölüm bulma - Sürekli

- Etkin hesaplama için, her öznitelik için
  - Değerleri sırala
  - Sıralı değerlerin üstünden git ve sınıf sayılarını güncelle
  - En az gini değeri var noktayı seç

Cheat	No	No	No	Yes	Yes	Yes	No	No	No	No
Taxable Income										
Sıralanmış değerler →	60	70	75	85	90	95	100	120	125	220
Bölüm opsiyonları →	55	65	72	80	87	92	97	110	122	172	230
	<= >	<= >	<= >	<= >	<= >	<= >	<= >	<= >	<= >	<= >	<= >
Yes	0 3	0 3	0 3	0 3	1 2	2 1	3 0	3 0	3 0	3 0	3 0
No	0 7	1 6	2 5	3 4	3 4	3 4	3 4	4 3	5 2	6 1	7 0
Gini	0.420	0.400	0.375	0.343	0.417	0.400	***0.300***	0.343	0.375	0.400	0.420

Uzayı bölme
Alternatif bölme kriteri

- T düğümü (node) için entropy:

$$Entropy(t) = -\sum_j p(j \mid t) \log p(j \mid t)$$

  - Düğüm homojenliğini ölçer
    - Maksimum ($\log n_c$) eğer sınıflar eşit dağılmışsa
    - Minimum 0 eğer düğüm homojen ise
  - Entropy hesaplamaları gini ile benzerdir

Uzayı bölme
Alternatif bölme kriteri - Entropy

$$Entropy(t) = -\sum_j p(j \mid t) \log_2 p(j \mid t)$$

C1	**0**
C2	**6**

P(C1) = 0/6 = 0 P(C2) = 6/6 = 1

Entropy = – 0 log 0 – 1 log 1 = – 0 – 0 = 0

C1	**1**
C2	**5**

P(C1) = 1/6 P(C2) = 5/6

Entropy = – (1/6) $\log_2$ (1/6) – (5/6) $\log_2$ (1/6) = 0.65

C1	**2**
C2	**4**

P(C1) = 2/6 P(C2) = 4/6

Entropy = – (2/6) $\log_2$ (2/6) – (4/6) $\log_2$ (4/6) = 0.92

Uzayı bölme
Bilgi kazanımı

- Bilgi kazanımı (Information Gain)

$$GAIN_{split} = Entropy(p) - \left(\sum_{i=1}^{k} \frac{n_i}{n} Entropy(i) \right)$$

Ebeveyn node, p k bölüme ayrılırsa;

n_i i bölümündeki gözlem sayısı

  - Bilgi kazanımını en fazlayan bölümü seç
  - Dezavantaj: Çok yüksek sayıda küçük homojen bölmelere neden olurç

Bilgi Kazanımı ölçümü

Information Gain = entropy(parent) – [average entropy(children)]

Tüm veri (30 gözlem)

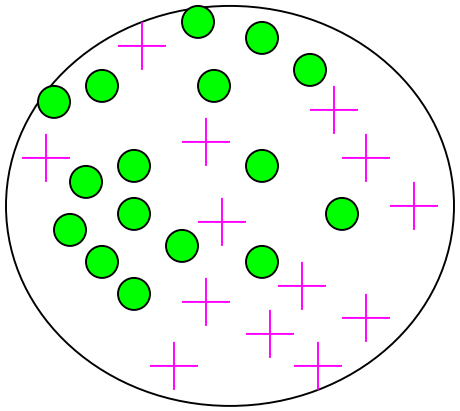

parent entropy $-\left(\frac{14}{30}\cdot\log_2\frac{14}{30}\right)-\left(\frac{16}{30}\cdot\log_2\frac{16}{30}\right)=0.996$

child entropy $-\left(\frac{13}{17}\cdot\log_2\frac{13}{17}\right)-\left(\frac{4}{17}\cdot\log_2\frac{4}{17}\right)=0.787$

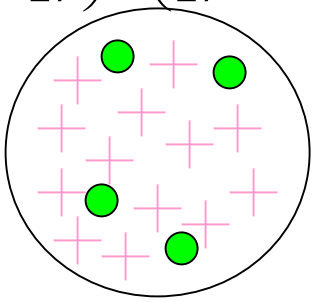

17 gözlem

child entropy $-\left(\frac{1}{13}\cdot\log_2\frac{1}{13}\right)-\left(\frac{12}{13}\cdot\log_2\frac{12}{13}\right)=0.391$

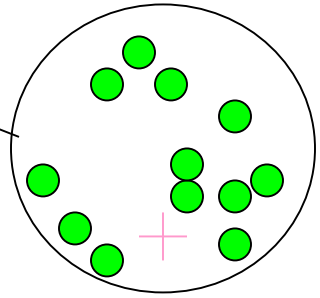

13 gözlem

Ortalama Entropy = $\left(\frac{17}{30}\cdot 0.787\right)+\left(\frac{13}{30}\cdot 0.391\right)=0.615$

Bilgi kazanımı = 0.996 - 0.615 = 0.38

Uzayı bölme
Hatadaki iyileşmeye göre

$$Error(t) = 1 - \max_i P(i \mid t)$$

C1	**0**
C2	**6**

P(C1) = 0/6 = 0 P(C2) = 6/6 = 1

Error = 1 – max (0, 1) = 1 – 1 = 0

C1	**1**
C2	**5**

P(C1) = 1/6 P(C2) = 5/6

Error = 1 – max (1/6, 5/6) = 1 – 5/6 = 1/6

C1	**2**
C2	**4**

P(C1) = 2/6 P(C2) = 4/6

Error = 1 – max (2/6, 4/6) = 1 – 4/6 = 1/3

Uzayı bölme
Ölçütler arası karşılaştırma

İki sınıflı problem içim

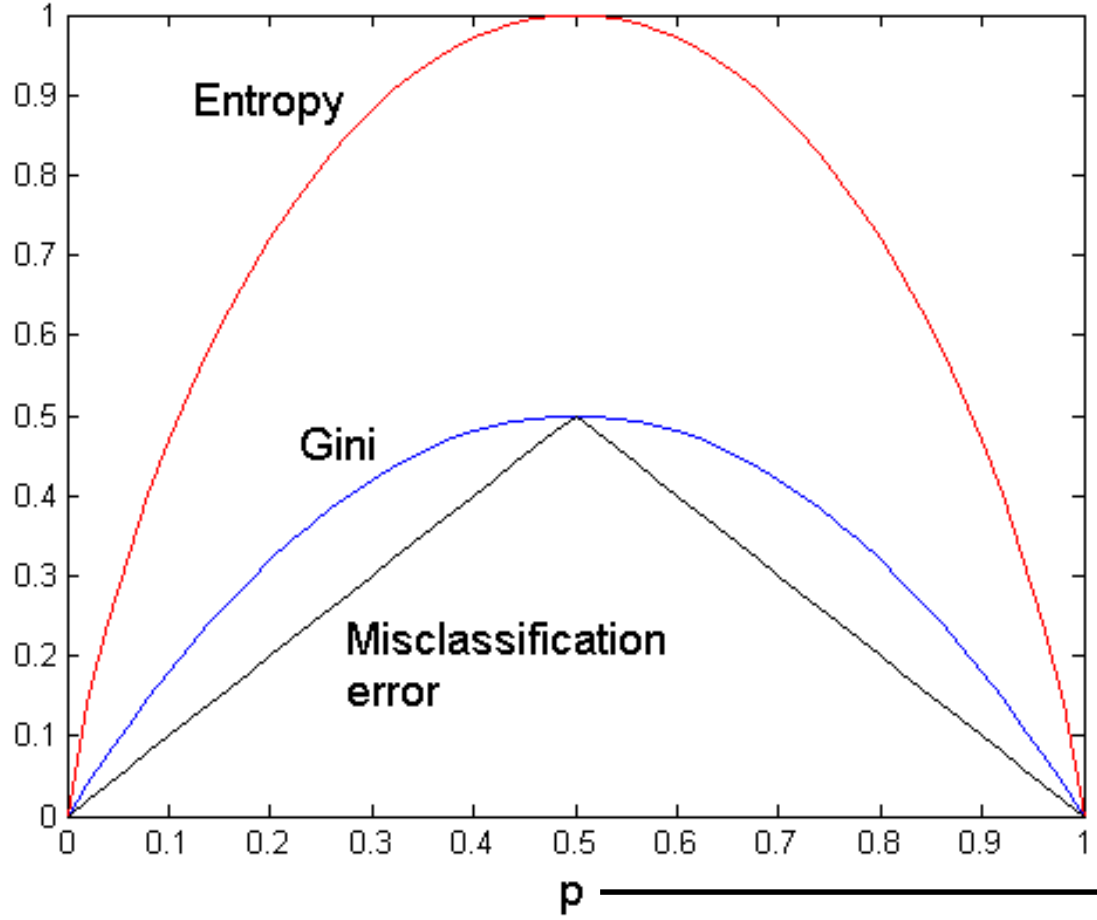

Uzayı bölme
Bölmeyi ne zaman durdurmalıyız?

#	Attribute				Class
	Outlook	Temperature	Humidity	Windy	Play
1	sunny	hot	high	no	N
2	sunny	hot	high	yes	N
3	overcast	hot	high	no	P
4	rainy	moderate	high	no	P
5	rainy	cold	normal	no	P
6	rainy	cold	normal	yes	N
7	overcast	cold	normal	yes	P
8	sunny	moderate	high	no	N
9	sunny	cold	normal	no	P
10	rainy	moderate	normal	no	P
11	sunny	moderate	normal	yes	P
12	overcast	moderate	high	yes	P
13	overcast	hot	normal	no	P
14	rainy	moderate	high	yes	N

Uzayı bölme
Bölmeyi ne zaman durdurmalıyız?

Basit bir ağaç

#	Attribute				Class
	Outlook	Temperature	Humidity	Windy	Play
1	sunny	hot	high	no	N
2	sunny	hot	high	yes	N
3	overcast	hot	high	no	P
4	rainy	moderate	high	no	P
5	rainy	cold	normal	no	P
6	rainy	cold	normal	yes	N
7	overcast	cold	normal	yes	P
8	sunny	moderate	high	no	N
9	sunny	cold	normal	no	P
10	rainy	moderate	normal	no	P
11	sunny	moderate	normal	yes	P
12	overcast	moderate	high	yes	P
13	overcast	hot	normal	no	P
14	rainy	moderate	high	yes	N

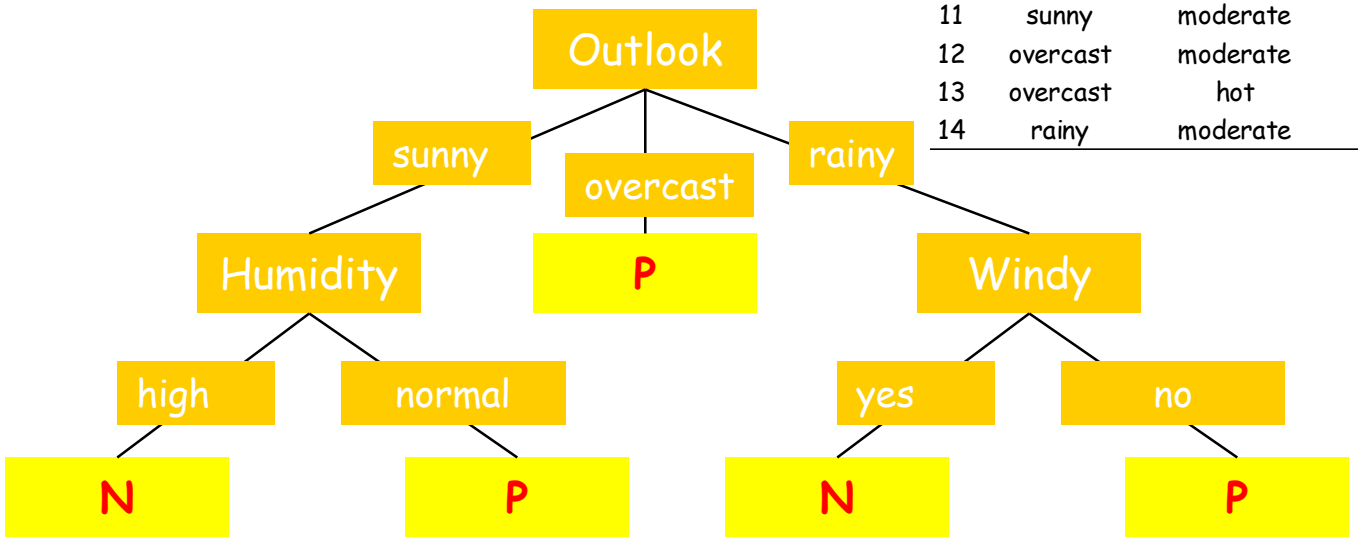

Uzayı bölme
Bölmeyi ne zaman durdurmalıyız?

Komplike bir ağaç

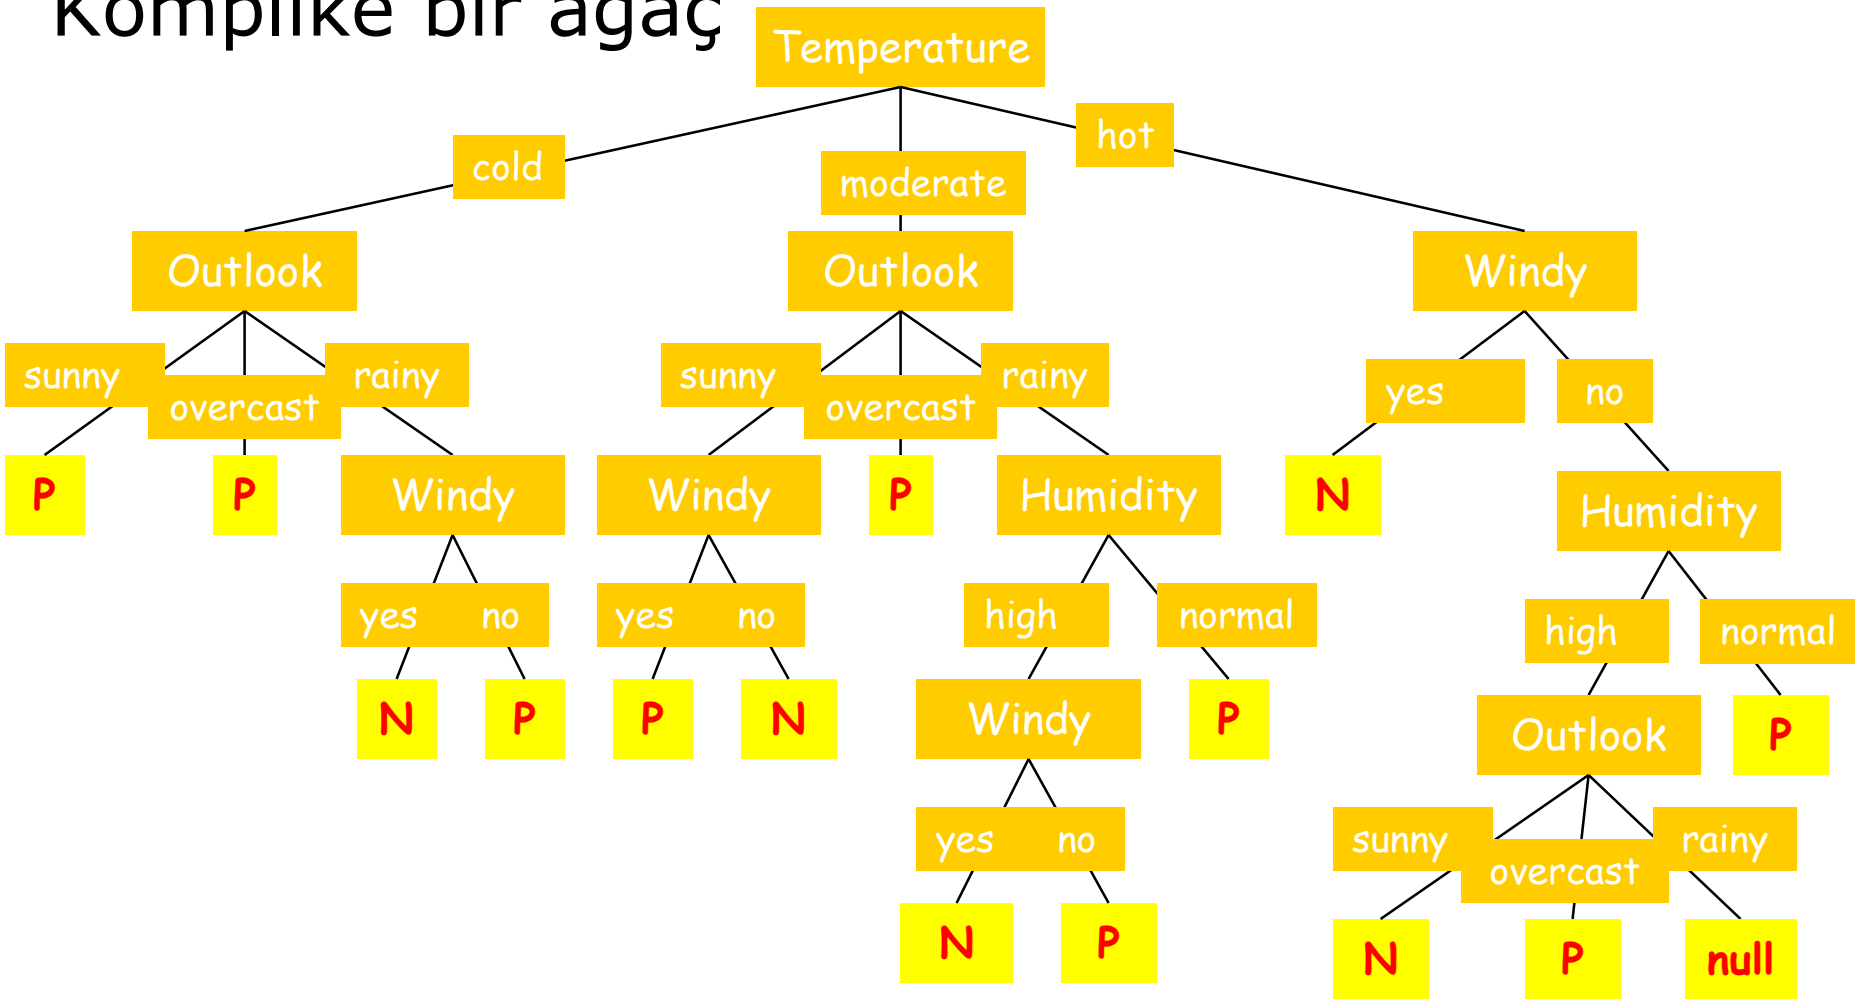

Uzayı bölme
Bölmeyi ne zaman durdurmalıyız?

- Bölüm yapmayı aşağıdaki koşullar sağlandığında bırakabiliriz
  - Belli bir saflık elde edildiğinde
    - Tüm gözlemler aynı sınıftaysa (sınıflandırma ağacı)
    - Tüm gözlemler benzer değerlere sahipse (regresyon ağacı)
  - Belli bir derinliğe ulaşıldığında
  - Belli bir düğüm sayısına ulaşıldığında
  - Saflık iyileştirilemiyorsa

Sınıflandırma ile ilgili önemli meseleler
Underfitting (yetersiz uyum) ve Overfitting (aşırı uyma)

- Test verisindeki performans nasıl olacak?

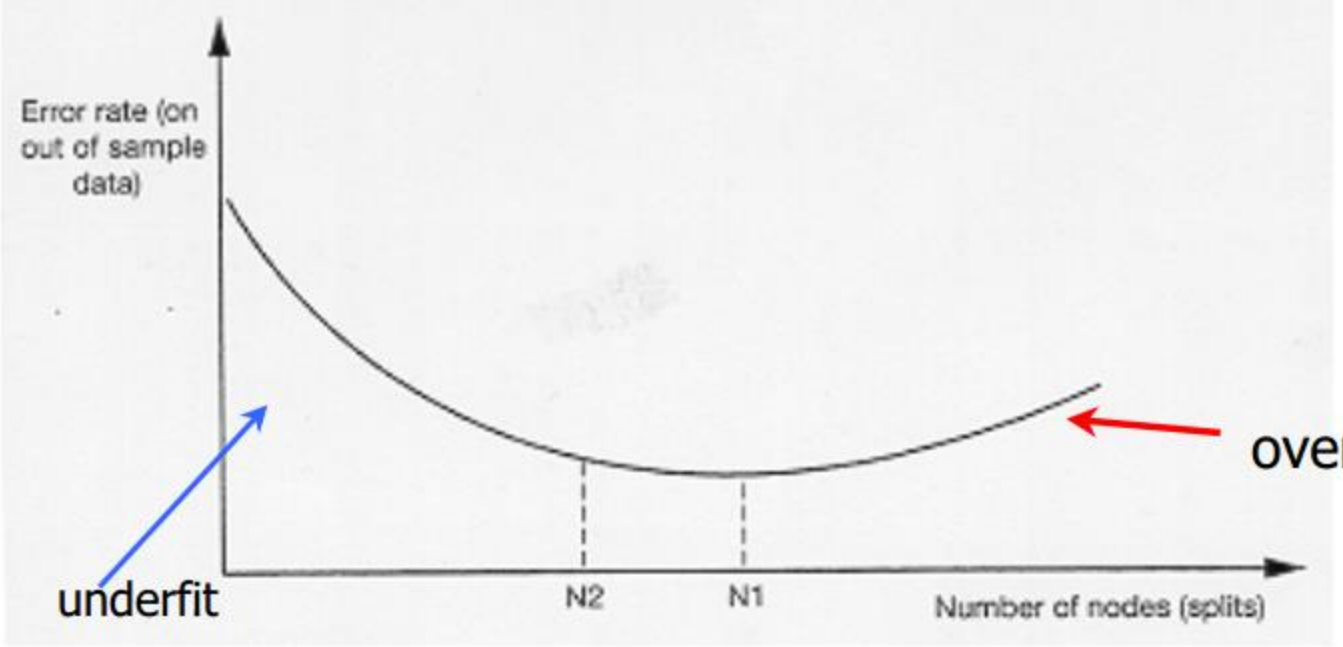

Model komplikasyonu
Düğüm sayısı

Sınıflandırma ile ilgili önemli meseleler
Underfitting (yetersiz uyum) ve Overfitting (aşırı uyma)

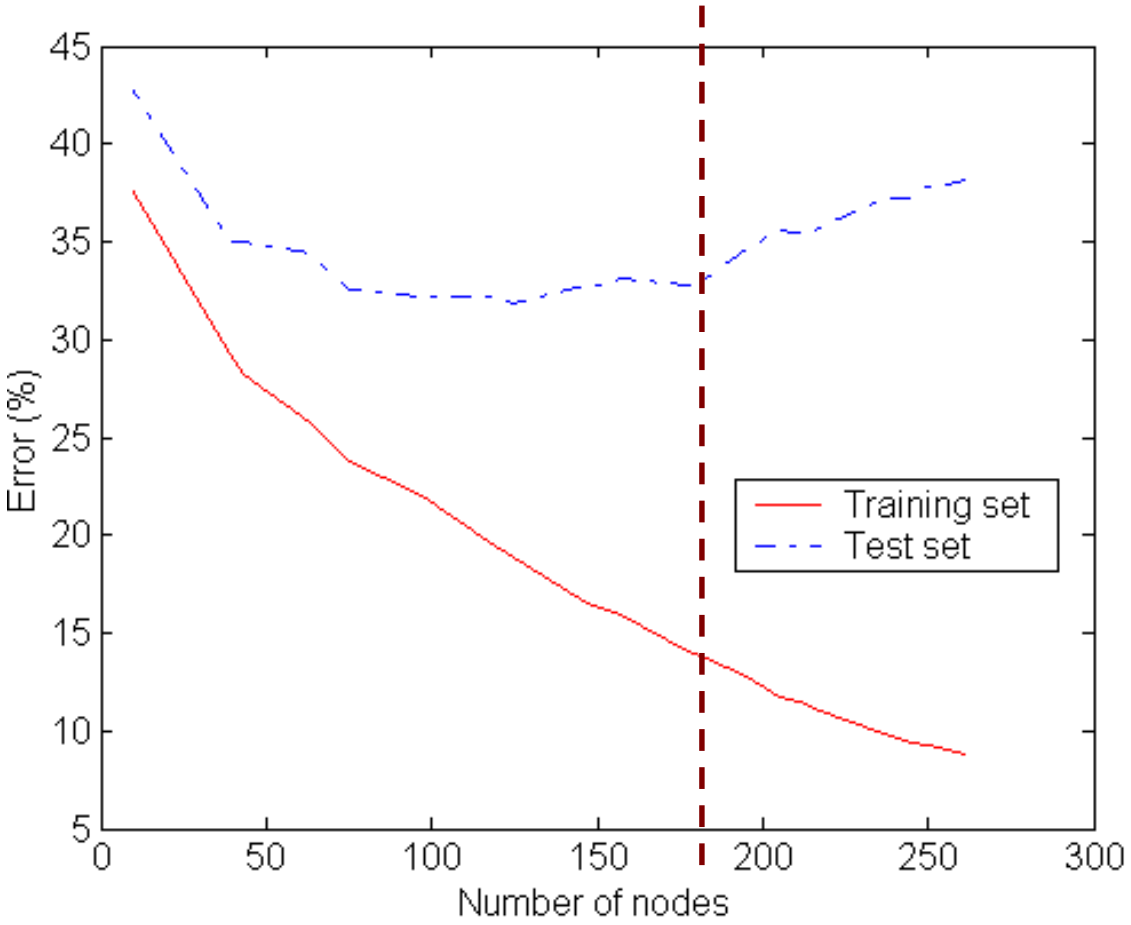

Overfitting: öğrenme verisini o kadar detaylı öğrenir ki, test verilerini tahmin etmede sorun yaşar

Underfitting: model o kadar basit kalır ki, test verisini tahmin etmek zorlaşır

Sınıflandırma ile ilgili önemli meseleler
Underfitting (yetersiz uyum) ve Overfitting (aşırı uyma)

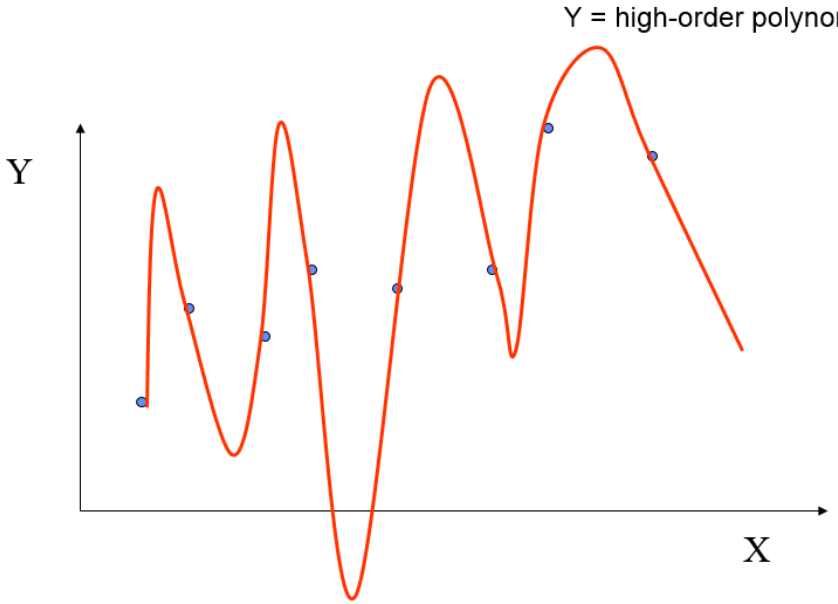

VEYA

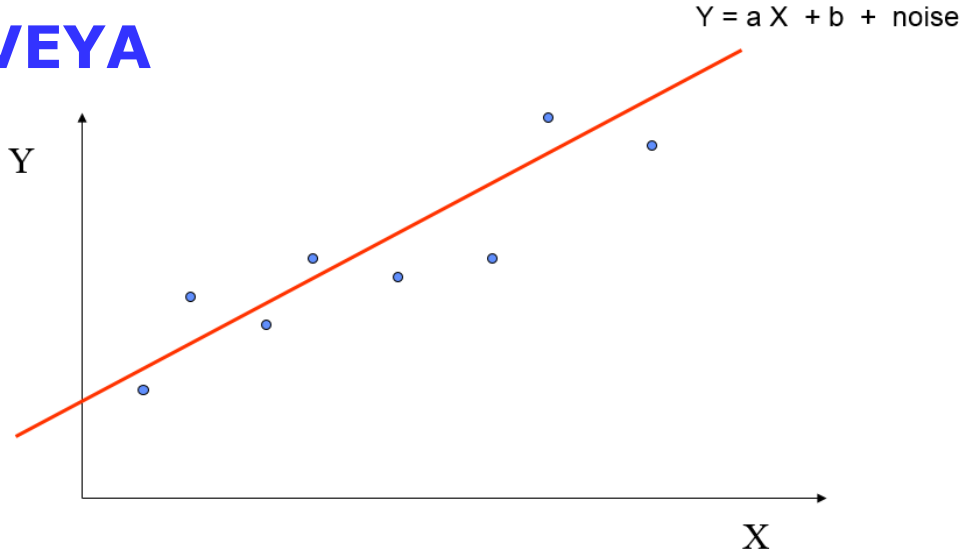

Sınıflandırma ile ilgili önemli meseleler
Overfitting (aşırı uyma) sebebiyle gürültü öğrenme

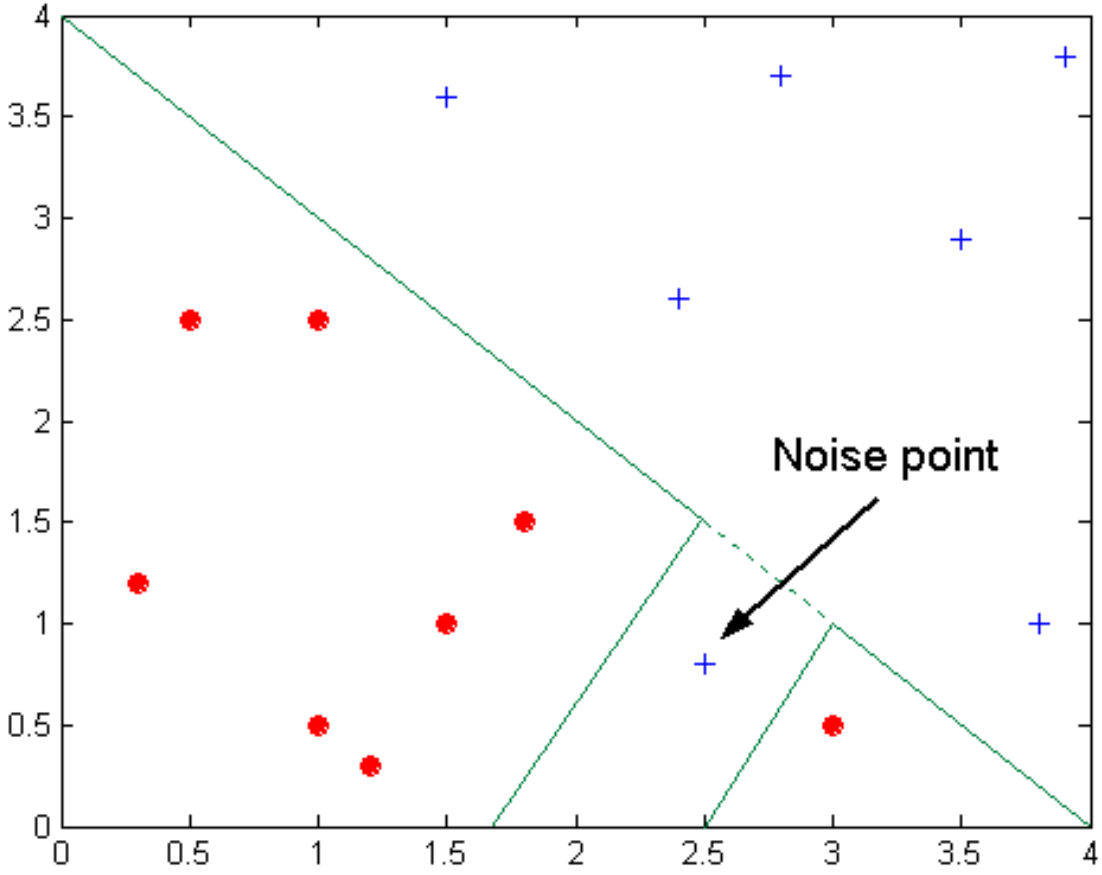

Karar verme sınırı gürültü sebebiyle bozulur

Tavsiyeler

- Farklı modelleri karşılaştırırken
  - Kullanımı kolay olanları
  - Model öğrenimi kolay
  - Gürültüye duyarlı olmayan
  - Açıklanabilir
  - Genelleştirmesi kolay (Occam's razor)

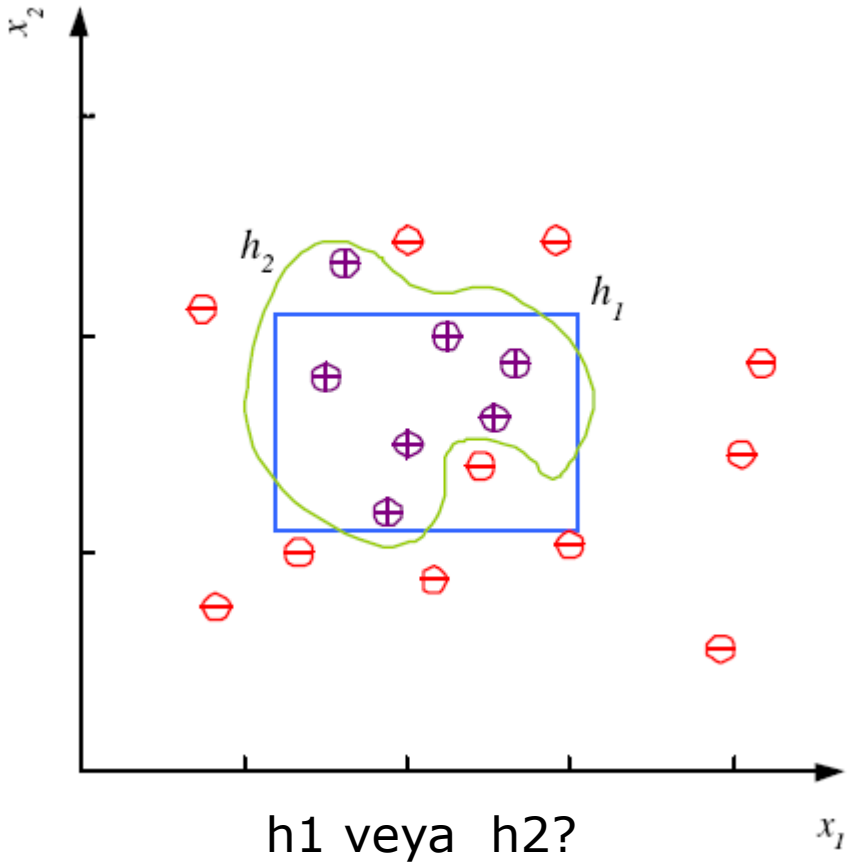

h1 veya h2?

Ağaçların avantajları

- Yorumlanması ve anlaşılması kolaydır.
- Minimal önişleme gerektirir. Diğer yöntemler:
  - Normalizasyon, kayıp değer tahmini, kategorik değerlerin sayısal değerlere çevrilmesi vb. gerektirir.
- Ağaç öğrenmesi ve ağaçtan tahmin yapması hızlıdır
- Sürekli, kategorik ve ordinal değişkenleri yapısını bozmadan ele alır.
- Veri dağılımı ile ilgili varsayımlardan etkilenmez
- Kendi içinde değişken seçimi yapar
  - Alakasız veya gürültülü veriden etkilenmesi minimaldir

Ağaçların dezavantajları

- Aşırı öğrenmeye meyillidir.
- Verideki ufak değişiklikler bambaşka bir ağaca sebep olabilir.
- Bazı tür karar sınırlarını bulmakta zorlanabilir
  - XOR
- Eğer belli bir sınıf çoğunluk ise, o sınıfı öğrenmeye meyillidir.
  - Öğrenimden önce sınıflar arası denge sağlanması gerekir
- Sürekli değişkenler üzerinden kural bulmaya meyillidir